시계열분석

10주차: VAR 모형

벡터시계열

- 여러 시계열을 동시에 고려하여 상호 연관성을 분석
- 예(3개의시계열):

  시계열1: $y_{1,t}$-분기별소비

  시계열2: $y_{2,t}$-분기별소득

  시계열3: $y_{3,t}$-분기별자산



- 벡터시계열의표현: $y_t = \begin{pmatrix} y_{1,t} \\ y_{2,t} \\ y_{3,t} \end{pmatrix}, t = 1,2,3, \ldots$

VAR(Vector Autoregression) 모형

- 한 시계열에 대한 AR(1) 모형: $y_t = \phi_1 y_{t-1} + \varepsilon_t$
- 두 시계열에 대한 VAR(1) 모형:

$$y_{1,t} = \phi_{11} y_{1,t-1} + \phi_{12} y_{2,t-1} + \varepsilon_{1,t}$$

$$y_{2,t} = \phi_{21} y_{1,t-1} + \phi_{22} y_{2,t-1} + \varepsilon_{2,t}$$

여기서 $\varepsilon_{1,t} \sim N(0, \sigma_1^2)$, $\varepsilon_{2,t} \sim N(0, \sigma_2^2)$이며, $cov(\varepsilon_{1,t}, \varepsilon_{2,t}) = \sigma_{12}$

$$y_t = \Phi_1 y_{t-1} + \varepsilon_t, \varepsilon_t \sim MVN(0, \Sigma), \Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$$

VAR(Vector Autoregression) 모형

- m차원 시계열의 VAR(1) 모형

$$y_t = \begin{pmatrix} y_{1,t} \\ y_{2,t} \\ y_{3,t} \end{pmatrix}; y_t = \Phi_1 y_{t-1} + \varepsilon_t$$ (여기서 Φ_1은 mxm행렬)

- m차원 시계열의 VAR(p) 모형

$$y_t = \Phi_1 y_{t-1} + \Phi_2 y_{t-2} + \cdots + \Phi_p y_{t-p} + \varepsilon_t$$

$$\Phi(x) = I - \Phi_1 x - \cdots - \Phi_p x^p \Rightarrow \Phi(B) y_t = \varepsilon_t$$

VAR 모형 전제: 정상성 검정

- VAR(1)모형의 정상성 조건

  $y_t = \Phi_1 y_{t-1} + \varepsilon_t$

  계수행렬 Φ_1의 고유치들의 크기가 모두 1보다 작아야 함.

  $\det\Phi(x) = \det(I - \Phi_1 x) = 0$의 근들의 크기가 모두 1보다 커야 한다.

- VAR(p)모형의 정상성 조건

  $y_t = \Phi_1 y_{t-1} + \Phi_2 y_{t-2} + \cdots + \Phi_p y_{t-p} + \varepsilon_t$

$\Phi(x) = I - \Phi_1 x - \cdots - \Phi_p x^p \Rightarrow \Phi(B) y_t = \varepsilon_t$

$\det\Phi(x) = \det\left(I - \Phi_1 x - \cdots - \Phi_p x^p\right) = 0$의 근들의 크기가 모두 1보다 커야 한다.

$y_t = F y_{t-1} + v_t$ 의 형태에서 행렬 F의 고유치들의 크기가 모두 1보다 작아야 한다.

VAR 모형 전제: 정상성 검정

- 다음의 두 시계열에 대한 VAR(2) 모형이 정상적인지 알아보자.

$$\begin{pmatrix} y_{1,t} \\ y_{2,t} \end{pmatrix} = \begin{bmatrix} 0.3 & -0.1 \\ -0.05 & 0.25 \end{bmatrix} \begin{pmatrix} y_{1,t-1} \\ y_{2,t-1} \end{pmatrix} + \begin{bmatrix} 0.2 & -0.75 \\ -0.1 & 0.4 \end{bmatrix} \begin{pmatrix} y_{1,t-2} \\ y_{2,t-2} \end{pmatrix} + \begin{pmatrix} \varepsilon_{1,t} \\ \varepsilon_{2,t} \end{pmatrix}, \Sigma = \begin{bmatrix} 0.6 & 0.05 \\ 0.05 & 1 \end{bmatrix}$$

```
eigen(data)$values
```

모형의 식별 – 시차p 결정

- 방법1: 이론적 ACF/PACF를 구하고 표본 ACF/PACF와 비교
  - 교차상관관계 등이 존재하므로 쉽지 않음
  - 개별 시계열에 대한 표본 ACF/PACF를 관찰하고 충분한 시차p를 추정할 수도 있음

- 방법2: 정보기준(information criteria) 사용
  실제적으로 널리 사용되고 있음
  여러 시차에 대해 AIC, BIC, HQ 등을 산출하고 정보기준값이 최소인 시차 선택
  - AIC(p): Akaike information criteria
  - BIC(p): Schwarz (Bayesian) information criteria
  - HQ(p): Hannan-Quinn information criteria

- 방법3: 우도비검정

모형의 식별

- 다음은 세 가지 벡터 시계열에 대한 여러 시차에 따른 VAR모형을 추정한 후 정보기준값을 산출한 결과이다. 적절한 시차 p를 선택하라.

Lag	LogL	LR	FPE	AIC	SC	HQ
0	-1415.48	NA	5.05e+11	35.46	35.55	35.49
1	-1070.11	656.19	1.13e+08	27.05	27.41*	27.19
2	-1055.28	27.07*	9.74e+07*	26.90*	27.53	27.16*
3	-1046.40	15.53	9.79e+07	26.91	27.80	27.27
4	-1039.98	10.75	1.05e+08	26.97	28.14	27.44
5	-1038.50	2.37	1.28e+08	27.16	28.59	27.73

그래인저 인과관계(Granger Causality)

- 시계열 $\{X_t, t \geq 1\}$이 시계열$\{Y_t, t \geq 1\}$의 미래값을 예측하는데 도움이 될 때, $\{X_t, t \geq 1\}$이 $\{Y_t, t \geq 1\}$에 영향을 준다 말한다.
- 그래인저 인과관계 검정

  자기회귀 시차모형:

$$Y_t = \alpha_0 + \alpha_1 Y_{t-1} + \cdots + \alpha_p Y_{t-p} + \beta_1 Y_{t-1} \ldots + \cdots + \beta_q Y_{t-q} + a_t$$

가설: $H_0: \beta_1 = \ldots = \beta_q = 0$

검정통계량: $F = \frac{(SSE_r - SSE_{ur})/q}{SSE_{ur}/(N-p-q-1)}$

- 결과 해석: 서로 영향을 주지 않을 때는 VAR모형 분석의 의미가 없음

그래인저 인과관계(Granger Causality) & VAR

lmtest 패키지 필요

vars 패키지 필요

- $grangertest(Y \sim X, order = k, data = data)$

  #x의 과거 k개 값들이 추가로 예측력을 높이는지

- $VARselect(dataframe, lag.max = lag, type = "const")$

  #여러 시차 중 AIC, BIC, HQ, FPE를 계산해 최적 시차 계산

- $VAR()$

  #다변량 VAR 모형을 추정

- $causality(var_mod, cause = "변수명")$

  #VAR 모형에서 지정한 cause 변수가 다른 계열에 Granger 인과성을 갖는지

그래인저 인과관계(Granger Causality) & VAR – 실습

lmtest 패키지 필요

vars 패키지 필요

- “EUStockMarkets” 데이터는 1991년부터 1998년까지 독일(DAX), 스위스(SMI), 프랑스(CAC)와 영국(FTSE) 주요 주가지수의 일별 종가를 담고 있다. 과거 5일 간의 DAX 정보가 SMI 예측에 도움이 되는가를 검정해보고 (그 반대도), lag를 최대 10차시까지 검토하여 최적의 시차를 선택해보자. 그 후, VAR 모형을 적합한 뒤 동일한 인과관계를 확인해보자.

그래인저 인과관계(Granger Causality) & VAR – 실습

```
> grangertest(SMI ~ DAX, order = 5, data = dt)
Granger causality test

Model 1: SMI ~ Lags(SMI, 1:5) + Lags(DAX, 1:5)
Model 2: SMI ~ Lags(SMI, 1:5)
  Res.Df Df      F  Pr(>F)
1   1844
2   1849 -5 2.3446 0.03921 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

모형1 (풀 모형):

$$\mathrm{SMI}_t = \alpha_0 + \sum_{i=1}^{5} \alpha_i \, \mathrm{SMI}_{t-i} + \sum_{i=1}^{5} \beta_i \, \mathrm{DAX}_{t-i} + \varepsilon_t$$

모형2 (제한 모형):

$$\mathrm{SMI}_t = \alpha_0 + \sum_{i=1}^{5} \alpha_i \, \mathrm{SMI}_{t-i} + u_t$$

그래인저 인과관계(Granger Causality) & VAR – 실습

```
> VARselect(df[,c("DAX","SMI")], lag.max = 10, type = "const")
$selection
AIC(n)  HQ(n)  SC(n) FPE(n)
    10      2      2     10

$criteria
                1           2           3           4           5           6           7           8           9          10
AIC(n)   13.52508    13.50310    13.50256    13.50668    13.50482    13.49756    13.49420    13.49762    13.49720    13.49301
HQ(n)    13.53168    13.51410    13.51796    13.52649    13.52903    13.52618    13.52721    13.53504    13.53902    13.53923
SC(n)    13.54299    13.53295    13.54435    13.56042    13.57050    13.57518    13.58376    13.59912    13.61065    13.61839
FPE(n) 747939.96806 731678.78991 731283.22365 734306.16186 732941.20126 727641.55557 725195.26876 727683.17142 727380.02401 724333.79088


Call:
DAX = DAX.l1 + SMI.l1 + DAX.l2 + SMI.l2 + const

     DAX.l1      SMI.l1      DAX.l2      SMI.l2       const
 1.06467062 -0.07980752 -0.08316828  0.09289677  4.82149495


Estimated coefficients for equation SMI:
========================================
Call:
SMI = DAX.l1 + SMI.l1 + DAX.l2 + SMI.l2 + const

      DAX.l1       SMI.l1       DAX.l2       SMI.l2        const
 0.094758749  0.999012736 -0.104023644  0.008088379  2.510746281
```

그래인저 인과관계(Granger Causality) & VAR – 실습

```
> #    DAX → SMI 인과관계 검정
> causality(var_mod, cause = "DAX")$Granger

        Granger causality H0: DAX do not Granger-cause SMI

data:  VAR object var_mod
F-Test = 3.7474, df1 = 2, df2 = 3706, p-value = 0.02367

> #    SMI → DAX 인과관계 검정
> causality(var_mod, cause = "SMI")$Granger

        Granger causality H0: SMI do not Granger-cause DAX

data:  VAR object var_mod
F-Test = 11.765, df1 = 2, df2 = 3706, p-value = 8.068e-06
```