시계열분석

12주차: 상태공간모형

상태공간모형 (State-space Model)

- 상태공간모형(state-space model)에서는 관측되는 변수와 관측되지 않는 변수를 구분
- 시간에 따라 변하는 관측되지 않는 변수를 상태변수(state variable)라 함.
- 상태변수도 확률변수로 간주
- 상태공간모형은 관측방정식(observation equation)과 상태방정식(state equation)의 2가지로 구성됨
- 회귀모형, ARMA모형 등을 포함하는 광범위한 모형임
- 다변량 시계열 역시 모형화 가능
- 시간에 따라 상태변수 및 관측변수가 변하는 동적시스템(dynamic system)에 주로 활용

모형의 표현

- (예1) 시간 t 관측치를 Yt라 할 때 이는 상태변수 μt와 관측오차 wt로부터 얻어지고 상태변수는 이전 시간의 상태와 오차 vt가 더해져 변한다고 하자. 이때, 상태공간 모형은 다음으로 표현된다.

  (관측방정식) $Y_t = \mu_t + w_t$

  (상태방정식) $\mu_t = \mu_{t-1} + v_t$

  오자항 가정: $w_t \sim N(0, \sigma_w^2),\ v_t \sim N(0, \sigma_v^2)$이며 다른 변수와 독립

- (예2) 시간 t 관측치를 Yt라 할 때 이는수준(level)변수 μt와 관측오차 εt로부터 얻어진다. 수준변수는 이전 시간의 수준, 추세(trend)와 오차 at가 더해져 변하고, 추세는 이전 추세와 오차 bt가 더해져 변한다고 하자. 이때, 상태공간모형은 다음으로 표현된다.

  (관측방정식) $Y_t = \mu_t + \varepsilon_t$

  (상태방정식) $\mu_t = \mu_{t-1} + \beta_{t-1} + a_t;\ \ \beta_t = \beta_{t-1} + b_t$

  → 상태변수가 2개임. 이 경우 벡터/행렬로 모형을 표현

일반적 모형 형태

- 관측변수: $y_t = (Y_{1t}, \ldots, Y_{dt})^T$
- 상태변수: $x_t = (X_{1t}, \ldots, X_{kt})^T$
- (관측방정식) $y_t = Gx_t + w_t,\ w_t \sim wn(O, R)$
- (상태방정식) $x_t = Fx_{t-1} + v_t,\ v_t \sim wn(O, Q)$

  G: (d x k) 계수 행렬

  F: (k x k) 계수 행렬

  R: 오차벡터의 w_t의 (d x d) 공분산 행렬

  Q: 오차벡터의 v_t의 (k x k) 공분산 행렬

상태공간모형 표현

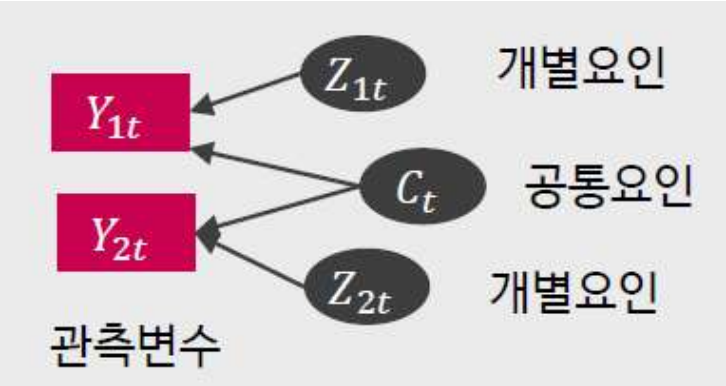
- 다음 모형을 일반적 형태 (벡터/행렬)로 표현하라.

  (관측방정식) $Y_t = \mu_t + \varepsilon_t;\ \varepsilon_t \sim N(0,\ \sigma_\varepsilon^2)$

  (상태방정식) $\mu_t = \mu_{t-1} + \beta_{t-1} + a_t;\ \ \beta_t = \beta_{t-1} + b_t;\ a_t \sim N(0,\ \sigma_a^2);\ b_t \sim N\left(0,\ \sigma_b^2\right)$

상태공간모형 표현

- 다음 그림과 같은 모형을 고려하자.



- 관측방정식: $Y_{1t} = \gamma_1 C_t + Z_{1t}; Y_{2t} = \gamma_2 C_t + Z_{2t}$
- 상태방정식:

  (공통요인) $C_t = \phi C_{t-1} + v_t,\ v_t \sim N(0,1)$

  (개별요인1) $Z_{1t} = a_1 Z_{1,t-1} + \varepsilon_{1t}, \varepsilon_{1t} \sim N(0, \sigma_1^2)$

  (개별요인2) $Z_{2t} = a_2 Z_{2,t-1} + \varepsilon_{2t}, \varepsilon_{2t} \sim N(0, \sigma_2^2)$

최적 선형 예측식

- 상태공간모형에서 미래의 관측치 $\boldsymbol{y}t$를 예측하기 위해서 우선 상태변수 $\boldsymbol{x}t$를 예측 필요
- 새로운 관측치가 발생할 때 상태변수의 예측식을 이전 예측식으로부터 갱신하는 것을 칼만필터(Kalmanfilter)라 함
- 칼만필터 식은 관측치의 선형함수에서 제곱합을 최소로 하는 계수 추정식 (즉, 최적 선형 예측식)으로부터 유도 됨
- 최적 선형 예측식은 결과적으로 베이지안기법에 의거 상태변수의 사전확률 분포로부터 사후 확률분포의 기대치 및 분산을 구하는 식과 동일함

최적 선형 예측식

- 목적: 확률변수 L을 예측하는데 관측치 Y의 선형식 사용
- 예측식 형태: $E[L|Y] = \alpha + \beta Y$
- 계수추정을 위해 다음 제곱합 기대치 최소화

$$Q = E[(L - \alpha + \beta Y)^2]$$

Q를 풀면:

$$Q = V[L] + E^2[L] + \beta^2\{V[Y] + E^2[Y]\} - 2\beta\{Cov[L,Y] + E[L]E[Y]\} + \alpha^2 - 2\alpha E[L] + 2\alpha\beta E[Y]$$

$$\alpha^* = E[L] - \beta^* E[Y]$$

$$\beta^* = \frac{Cov[L,Y]}{Var[Y]}$$

최적 선형 예측식

$$E^*[L|Y] = \alpha^* + \beta^* Y = E[L] + \frac{Cov[L,Y]}{V[Y]}(Y - E[Y])$$

$$Q^* = V[L] - \frac{Cov^2[L,Y]}{V[Y]}$$

칼만필터

- 최적선형예측식

$$E^*[L|Y] = \alpha^* + \beta^* Y = E[L] + \frac{Cov[L,Y]}{V[Y]}(Y - E[Y])$$

- 시계열 $Y_t, Y_{t-1}, Y_{t-2}, \dots$ 있는 경우

  $E[L|Y] = E[L|Y_t, Y_{t-1}, \dots]$: 가장 최근 관측치 Y_t를 포함한 조건부 기대치

  $E[L] = E[L|Y_{t-1}, \dots]$: 최근 관측치 Y_t가 없고 과거치만의 조건부 기대치

- 아래 최적 선형 예측식을 칼만필터라 함

$$E[L|Y_t, Y_{t-1}, \dots] = E[L|Y_{t-1}, \dots] + \frac{Cov[L, Y_t|Y_{t-1}, \dots]}{V[Y_t|Y_{t-1}, \dots]}(Y_t - E[Y_t|Y_{t-1}, \dots])$$

칼만필터

- 다음 모형에서 상태변수들의 칼만필터식을 유도하라.

  (관측방정식) $Y_t = \mu_t + \varepsilon_t;\ \varepsilon_t \sim N(0,\ \sigma_\varepsilon^2)$

  (상태방정식) $\mu_t = \mu_{t-1} + \beta_{t-1} + a_t;\ \ \beta_t = \beta_{t-1} + b_t;\ a_t \sim N(0,\ \sigma_a^2);\ b_t \sim N\left(0,\ \sigma_b^2\right)$

- 기호정의

$$l_t = E[\mu_t | Y_t, \dots],\ m_t = E[\beta_t | Y_t, \dots]$$

$$p_t = V[\mu_t | Y_t, \dots],\ q_t = V[\beta_t | Y_t, \dots],\ r_t = Cov[\mu_t, \beta_t | Y_t, \dots]$$

칼만필터 in R

MASS 패키지 필요

```
library(MASS)


# 1) 모델 파라미터
F1 <- matrix(c(1,1,0,1), 2, 2, byrow=T)
H <- matrix(c(1,0), 1, 2)
Q <- diag(c(9,4))   # σ_a^2 = 9, σ_b^2 = 4
R <- 25             # σ_ε^2 = 25
```

칼만필터 in R

MASS 패키지 필요

```
# 2) Riccati 반복으로 steady-state P, K 구하기
P <- diag(2)        # 초기값 (무엇이든 양의정부호면 OK)
for(i in 1:2000){
  Pp <- F1 %*% P %*% t(F1) + Q              # (a) 공분산 예측
  S  <- H %*% Pp %*% t(H) + R               #     잔차 분산
  K  <- Pp %*% t(H) %*% solve(S)            # (b) 칼만 이득
  P  <- (diag(2) - K %*% H) %*% Pp          # (c) 공분산 업데이트
}
P_ss <- P    # 수렴된 예측 공분산 P_{t|t-1}
K_ss <- K    # 수렴된 칼만 이득
```

칼만필터 in R

MASS 패키지 필요

```
# 3) steady-state 값 확인
p_ss    <- P_ss[1,1]    # Var(level)
r_ss    <- P_ss[1,2]    # Cov(level,slope)
q_ss    <- P_ss[2,2]    # Var(slope)
Kmu_ss  <- K_ss[1,1]    # K^μ
Kbeta_ss<- K_ss[2,1]    # K^β


data.frame(p_ss, r_ss, q_ss, Kmu_ss, Kbeta_ss)
```

칼만필터 in R

```
x <- matrix(c(l0, m0), 2, 1)   # 초기 상태 벡터
for (t in 1:length(y)) {     #y: 데이터
      x_pred <- F1 %*% x    # 예측 단계
      y_pred <- H %*% x_pred   # 측정값 예측 및 오차 계산
      e <- y[t] - y_pred
       x <- x_pred + K_ss %*% e   # 정상 상태 칼만 이득을 사용한 상태 업데이트
      lt[t] <- x[1]
      mt[t] <- x[2]
}
data.frame(years,  y, lt, mt)
```

칼만필터 예시

- Y_t는 연도별 금 가격 (온스당 미화달러)을 나타낸 것이다. 앞의 모형을 이용하여 상태변수들의 칼만필터 공식에 적용해보자. 오차항은 분산은 $\sigma_a^2 = 9$, $\sigma_b^2 = 4$, $\sigma_\varepsilon^2 = 25$ 이고, 초기치는 $l_0 = 100, m_0 = 0, p_0 = q_0 = 1, r_0 = 0$ 이다.

년도	Y_t	l_t	m_t	p_t	q_t	r_t	K_t^μ	K_t^β
2011	1571.5							
2012	1669.0							
2013	1411.2							
2014	1266.4							
2015	1160.1							
2016	1250.8							

12주차 과제

- Eclass 내 12주차 과제를 푸세요.