시계열분석

3주차: 시계열 데이터 탐색2

업샘플링(Upsampling) 개념

- 업샘플링: 더 낮은 빈도의 시계열을 더 높은 빈도로 변환하는 과정
  예) 월별 데이터를 일별로 늘리거나, 일별 데이터를 시간별로 세분화

- 목적:
  1) 세분화 분석: 더 촘촘한 단위로 패턴을 파악 (일별 판매량 → 시간별 판매량)
  2) 모델 요구: 예측 모델이 특정 빈도를 요구하는 경우 (예: LSTM 등 딥러닝 모델)

- 주의점: 실제로 존재하지 않는 시간 구간이 새로 생기므로, 결측치(NA) 처리가 필요
  예) 이전 값으로 채우기(LOCF), 선형 보간 등

업샘플링 - 실습

"Lec3_emails.csv" 데이터는 이메일 열어본 기록을 담은 시계열형 로그 데이터이다. 변수는 다음과 같다.

- emailsOpened: 특정 시점에 사용자가 열람(Opened)한 이메일의 개수
- user: 사용자 고유 번호
- week: 열람 시간

data.table 라이브러리에 있는 fread() 함수로 데이터를 불러와 week 열을 Date 타입으로 변환해보자.

```
emails <- fread("Lec3_emails.csv")
emails[, week := as.Date(week)]
```

업샘플링 - 실습

주 (week) 단위 별로 이메일 열람 횟수를 집계해보자.

```
daily_emails <- emails[, .(count_emails = .N), by = week]
```

전체 날짜 시퀀스를 생성해보자.

힌트: seq(from = ?, to = ?, by = ?)

```
all_dates <- seq(from =                    ,
                 to   =                    ,
                 by   =          )
```

업샘플링 - 실습

daily_emails 테이블에 대해 키를 week로 설정해보자.

```
setkey(daily_emails, week)
```

all_dates 벡터를 조인 키로 사용해 daily_emails를 조회하여 원래 없던 날짜가 NA로 표시해보자.

```
upsampled <- daily_emails[.(all_dates)]
```

```
> head(upsampled, 10)
          week count_emails
        <Date>        <int>
 1: 2015-02-09           46
 2: 2015-02-10           NA
 3: 2015-02-11           NA
 4: 2015-02-12           NA
 5: 2015-02-13           NA
 6: 2015-02-14           NA
 7: 2015-02-15           NA
 8: 2015-02-16           42
 9: 2015-02-17           NA
10: 2015-02-18           NA
```

업샘플링 - 실습

NA를 0으로 대체해보자.

```
upsampled[is.na(count_emails), count_emails := 0]
```

data.table에서 현재 행 번호(1부터 시작)를 기준으로 7일씩 묶어보자.

예) 1~7행 -> block=1, 8~14행 -> block=2, ...

```
upsampled[, block := floor((.I - 1) / 7) + 1]
```

```
> upsampled
           week count_emails block
         <Date>        <int> <num>
   1: 2015-02-09           46     1
   2: 2015-02-10            0     1
   3: 2015-02-11            0     1
   4: 2015-02-12            0     1
   5: 2015-02-13            0     1
  ---
1201: 2018-05-24            0   172
1202: 2018-05-25            0   172
1203: 2018-05-26            0   172
1204: 2018-05-27            0   172
1205: 2018-05-28          320   173
```

업샘플링 - 실습

업샘플링을 해보자.

일별 값을 해당 블럭의 합의 평균 값을 올림하여 사용해보자.

예) 1번 블록은 46/7 = 6.571, 올림하면 7

```
upsampled[, count_emails := {
  total <- sum(count_emails)      # 해당 블록(7일) 합
  avg   <- total / .N             # .N : 현재 그룹(블록) 내 행 개수
  val   <- ceiling(avg)           # 올림 처리
  rep(val, .N)                    # 블록 내 각 행(일자)에 동일한 값 할당
}, by = block]
```

```
> head(upsampled, 30)
          week count_emails block
        <Date>        <int> <num>
 1: 2015-02-09            7     1
 2: 2015-02-10            7     1
 3: 2015-02-11            7     1
 4: 2015-02-12            7     1
 5: 2015-02-13            7     1
 6: 2015-02-14            7     1
 7: 2015-02-15            7     1
 8: 2015-02-16            6     2
 9: 2015-02-17            6     2
10: 2015-02-18            6     2
11: 2015-02-19            6     2
12: 2015-02-20            6     2
13: 2015-02-21            6     2
14: 2015-02-22            6     2
```

3주차 과제 #1

- “Lec3_emails.csv” 데이터를 활용하여 eclass 내 3주차 과제#1을 풀어보자.

영어 로캘 설정:

```
Sys.setlocale("LC_TIME", "C")
```

A라는 날짜 열을 기준으로 요일을 출력하는 방법:

```
weekdays(A, abbreviate = FALSE)
```

다운샘플링(Downsampling) 개념

- 다운샘플링: 더 높은 빈도의 시계열(촘촘한 간격으로 측정된 데이터)을 더 낮은 빈도(간격이 큰 주기)로 변환하는 과정
  예) 일별 데이터를 주별 또는 월별로 묶어서 집계하는 것

- 목적:
  1) 노이즈(Noise) 제거: 시계열이 너무 세밀하게 관측된 경우, 일시적인 변동(잡음)이 두드러질 수 있으므로 다운샘플링을 통해 큰 흐름(추세, 계절성)에 더 집중
  2) 분석 및 시각화 단순화: 주기(week), 월(month), 분기(quarter) 등으로 요약하면, 의사결정에 필요한 핵심 정보를 빠르게 파악할 수 있음.

다운샘플링 - 실습

1) 계절 주기의 특정 부분에 집중하는 경우

2주차에서 다뤘던 "Lec2_UNRATE.csv" 데이터를 다시 불러와보자.

```
unemp <- fread("Lec2_UNRATE.csv")
unemp[, DATE := as.Date(DATE)]
```

```
> unemp
          DATE UNRATE
        <Date>  <num>
  1: 1948-01-01    3.4
  2: 1948-02-01    3.8
  3: 1948-03-01    4.0
  4: 1948-04-01    3.9
  5: 1948-05-01    3.5
 ---
840: 2017-12-01    4.1
841: 2018-01-01    4.1
842: 2018-02-01    4.1
843: 2018-03-01    4.1
844: 2018-04-01    3.9
```

월 단위로 구성된 원본 시계열에 다운샘플링을 적용하여 1월에 측정된 것만 출력해보자.

```
unemp[seq.int(from=1, to=nrow(unemp), by=12)]
```

다운샘플링 - 실습

- 2) 더 낮은 빈도의 데이터에 맞추는 경우

연도별 실업률 평균을 살펴보자.

```
unemp[,mean(UNRATE), by=format(DATE, "%Y")]
```

	format	V1
	<char>	<num>
1:	1948	3.750000
2:	1949	6.050000
3:	1950	5.208333
4:	1951	3.283333
5:	1952	3.025000
6:	1953	2.925000
7:	1954	5.591667
8:	1955	4.366667
9:	1956	4.125000
10:	1957	4.300000

월별 평균을 살펴보자.

```
unemp[, .(avg_unrate = mean(UNRATE)), by = .(month = format(DATE, "%m"))]
```

	month	avg_unrate
	<char>	<num>
1:	01	5.760563
2:	02	5.759155
3:	03	5.769014
4:	04	5.766197
5:	05	5.785714
6:	06	5.802857
7:	07	5.798571
8:	08	5.791429
9:	09	5.778571
10:	10	5.792857
11:	11	5.782857
12:	12	5.791429

3주차 과제 #2

- “Lec3_donations.csv” 데이터는 일별 기부금에 관련된 데이터이다. 변수 설명은 다음과 같다. 이 데이터를 활용하여 eclass 내 3주차 과제#2을 풀어보자.

변수명	설명
amount	기부금액 (단위: $)
timestamp	기부시간
user	기부자 고유 번호

```
floor_date(timestamp, "month")    #해당 타임스탬프를 해당 달의 1일 00:00:00로 내림 (lubridate 패키지)
floor_date(timestamp, “week”)     #해당 타임스탬프를 주 단위로 일요일 00:00:00로 내림 (lubridate 패키지)
```