시계열분석

5주차: ARIMA 모형 개요

Holt 지수평활법 (Holt's Linear Method)

- 단순 지수평활법(SES)은 수준(Level)만을 고려하기 때문에, 데이터에 추세(Trend)가 있을 경우 이를 반영하지 못함.
- Holt 방법은 추세를 반영할 수 있도록 설계되어, 시간이 지남에 따라 수준(Level)과 추세(Trend)를 동시에 업데이트함.

$$\hat{y}_{t+h} = L_t + hT_t$$

Level(수준)　　Trend(추세)

Holt 지수평활법 (Holt's Linear Method)

$$\hat{y}_{t+h} = L_t + hT_t$$

$$L_t = \alpha y_t + (1-\alpha)(L_{t-1} + T_{t-1})$$

$$T_t = \beta(L_t - L_{t-1}) + (1-\beta)T_{t-1}$$

- L_t: 시점 t에서의 수준(평활된 값)
- T_{t-1}: 이전 시점의 추세

계수	역할	값이 크면	값이 작으면
α (수준)	최근 관측값 vs 이전 수준 가중치	최근 관측에 민감 (노이즈 많음)	과거 추세 중심 (부드러움)
β (추세)	최근 추세 변화 vs 이전 추세 가중치	추세 변화에 빠르게 반응	추세를 천천히 갱신

Holt 지수평활법 예시

아래는 5개의 시점에 대한 관측값이다. 평활계수 $\alpha=0.5$, $\beta=0.3$으로 설정하여 t=6을 Holt 지수평활법으로 예측해보자.

시점(t)	실제값(y_t)	L_t	T_t
1	10	10	12-10=2
2	12		
3	11		
4	13		
5	15		

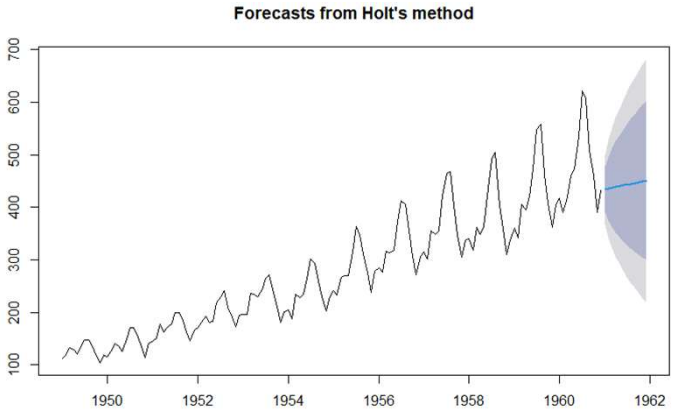
Holt 지수평활법 - 실습

forecast 패키지 필요

```
fit <- holt(ts_data, alpha = 0.5, beta = 0.3, h = 1)
```

- h: 예측하고자 하는 미래 시점 개수

```
summary(fit)
accuracy(fit)
```



Lec4_AirPassengers.csv 데이터를 불러와 setnames() 함수를 이용하여 Date 와 Passengers 이름을 지정하고 ts()함수로 월별 시계열 데이터 ts_air를 만들어보자.

α=0.8, β=0.01로 하여 Holt 지수평활법으로 1년을 예측해보자.

그리고 평활계수 없이 돌려보자.

Holt-Winters 지수평활법 (Holt-Winters Method)

- Holt-Winters 방법은 Holt 지수평활법을 기반으로 하며, 추세(Trend)뿐만 아니라 계절성(Seasonality)도 반영할 수 있음.
- 데이터가 추세와 계절성 모두를 보이는 경우, 이 방법을 사용하면 시계열의 전체 구조를 보다 정확하게 모델링할 수 있음.
- Additive 모델: 계절 효과가 절대적(덧셈)인 경우
- Multiplicative 모델: 계절 효과가 비례적(곱셈)인 경우

$$\hat{y}_{t+h} = (L_t + hT_t) \times S_{t+h-m}$$

Level(수준) Trend(추세) 계절성(Seasonality)

Holt-Winters 지수평활법 (Holt-Winters Method)

$$\hat{y}_{t+h} = (L_t + hT_t) \times S_{t+h-m}$$

Multiplicative $$L_t = \alpha \frac{y_t}{S_{t-m}} + (1-\alpha)(L_{t-1} + T_{t-1})$$

Additive $$L_t = \alpha(y_t - S_{t-m}) + (1-\alpha)(L_{t-1} + T_{t-1})$$

$$T_t = \beta(L_t - L_{t-1}) + (1-\beta)T_{t-1}$$

Multiplicative $$S_t = \gamma \frac{y_t}{L_t} + (1-\gamma)S_{t-m}$$

Additive $$S_t = \gamma(y_t - L_t) + (1-\gamma)S_{t-m}$$

Holt-Winters 지수평활법 (Holt-Winters Method)

- Additive vs Multiplicative — 언제 어떤 모형을 쓸까?

모형	특징	적합한 데이터
Additive	계절 효과 = 절대적 크기 (±상수)	계절 진폭이 시간이 지나도 일정
Multiplicative	계절 효과 = 수준에 비례 (×배율)	계절 진폭이 시간이 지남에 따라 커짐

Holt-Winters 지수평활법 (Holt-Winters Method) 예시

아래는 5개의 시점에 대한 관측값이다. 평활계수 α=0.5, β=0.3, γ=0.2로 설정하고 계절주기를 m=2로 설정하여 Holt-Winters Additive 모형으로 시점 t=6을 예측해보자.

초기값: L_0=11, S_1=-1, S_2=1, T_0=1

시점(t)	실제값(y_t)	L_t	T_t	S_t
1	10	11		-1
2	12			1
3	11			
4	13			
5	15			

Holt-Winters 지수평활법 - 실습

forecast 패키지 필요

```
fit1 <- HoltWinters(ts_air, alpha=0.3, beta=0.2, gamma=0.7, seasonal = "additive")
forecast_add <- forecast(fit1, h = 12)
h: 예측하고자 하는 미래 시점 개수
summary(forecast_add)
plot(fit1)
plot(forecast_add)
```

ts_air로 α=0.5, β=0.03, γ=0.8로 하여 Holt-Winters 지수평활법(additive)으로 1년을 예측해보자.
그리고 평활계수 없이 돌려보자.

Holt-Winters 지수평활법 - 실습

forecast 패키지 필요

앞의 실습에 multiplicative 도 추가하고 잔차를 진단해보자.

1) 잔차 시계열 확인

2) 잔차 ACF – 백색 잡음인지 확인

개념 확인 문제:

아래 두 시계열이 있다.

(A) 평균이 100 근처이고, 계절 진폭이 매년 ±10 수준으로 일정함

(B) 평균이 매년 증가하며, 계절 진폭도 함께 커짐 (초기 ±10 → 말기 ±40)

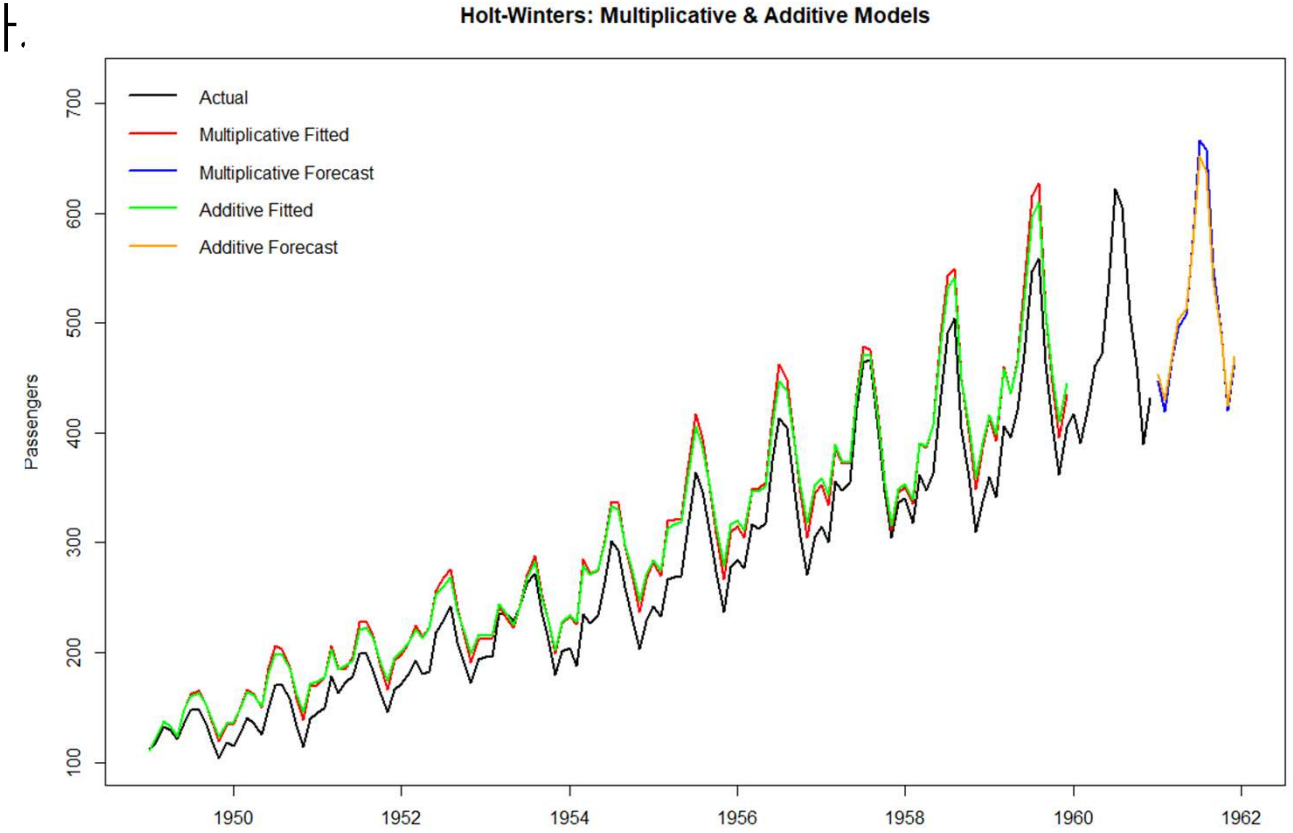
(A)와 (B) 각각에 더 적합한 Holt-Winters 모형을 선택하고 이유를 설명하시오. Multiplicative 모형에서 $\gamma=0$에 가까울 때 계절지수는 어떻게 갱신되는가?

5주차 과제 #1

- ts_air 데이터를 활용하여 eclass 내 5주차 과제#1을 풀어보자.

5주차 과제 #2

- ts_air 데이터를 Holt-Winters 모형으로 추정한 결과물을 다음과 같이 결과물을 시각화 해보자.



Gaussian White Noise Process

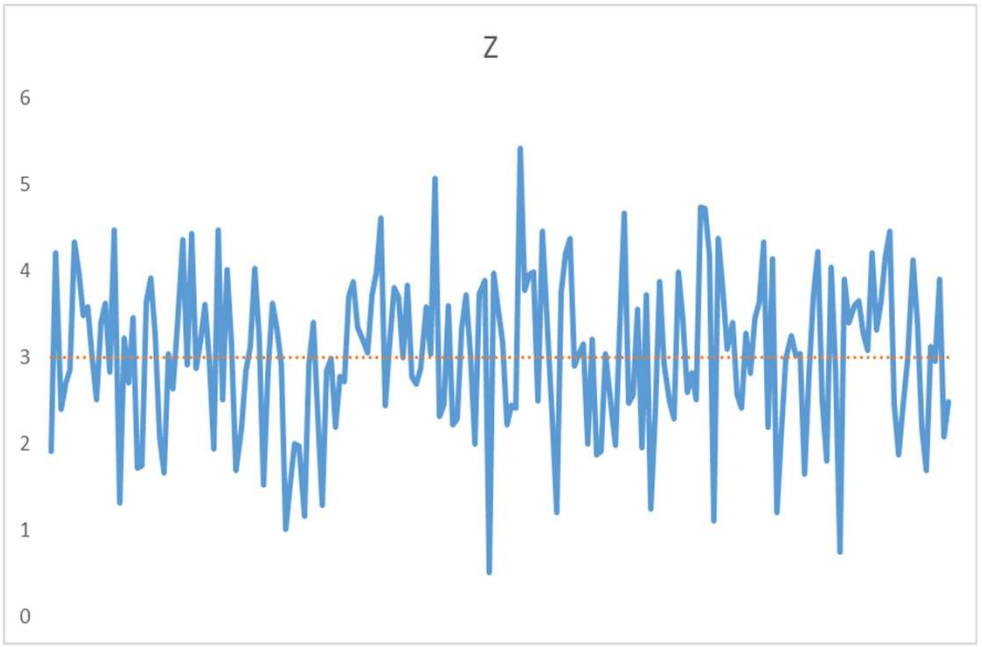
- $Z_t = \mu + \varepsilon_t$, where $\{\varepsilon_t\}$ mutually uncorrelated in Normal dist. with mean 0 and variance σ^2

$$\begin{bmatrix} Z_1 \\ Z_2 \\ \vdots \\ Z_T \end{bmatrix} = \mu \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_T \end{bmatrix}$$

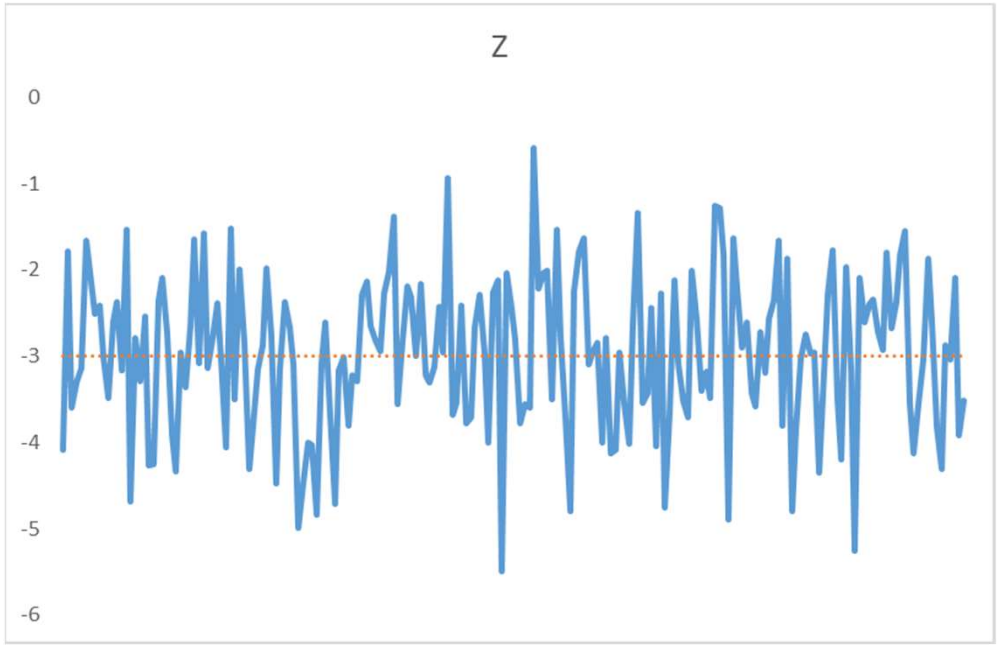
1. 평균 =0
2. 분산 일정
3. 공분산 =0, t와 s가 달라야함 ->서로 다른 두 시점에서 입실론의 상관관계는 없어야함
=> 3개 모두 만족해야 백색 잡음

Gaussian White Noise Process

$\mu = 3$



$\mu = -3$



Gaussian White Noise Process

- Theoretical Autocorrelation Function (ACF)

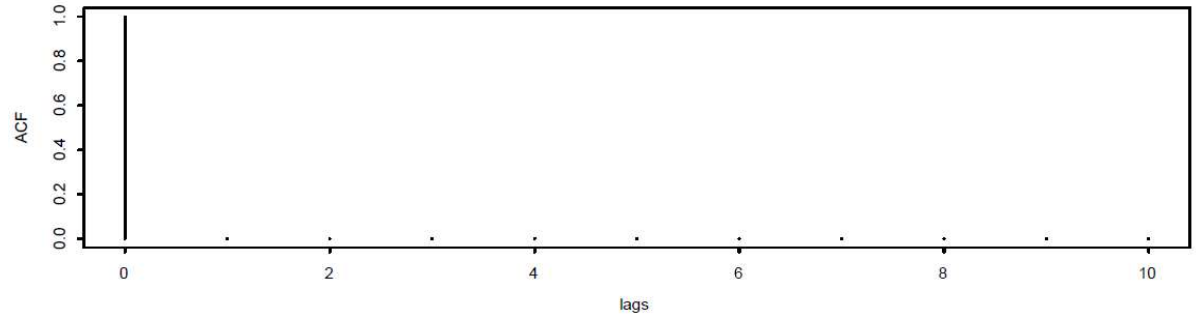
$$\rho_k = \frac{COV(Z_t, Z_{t-k})}{V(Z_t)}$$

- Sample Autocorrelation Function (SACF)

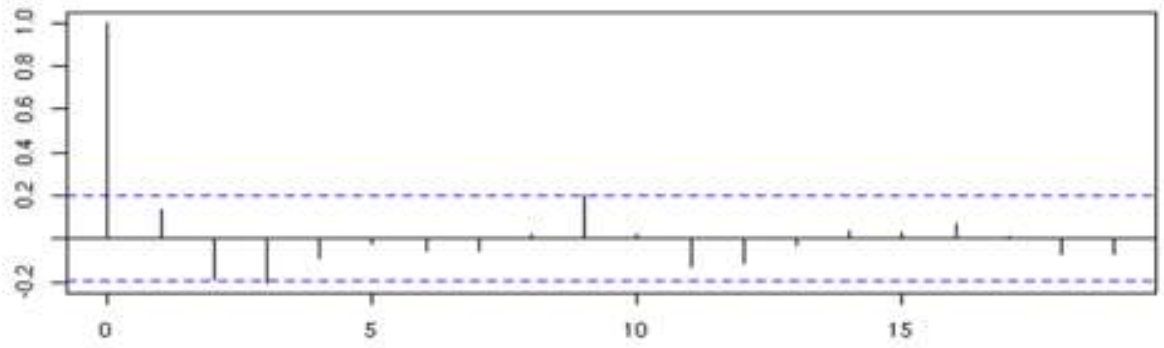
$$\widehat{\rho_k} = \frac{\sum_{t=k+1}^{T}(Z_t - \bar{Z})(Z_{t-k} - \bar{Z})/(T-k)}{\sum_{t=1}^{T}(Z_t - \bar{Z})^2/T}$$

Gaussian White Noise Process

- Theoretical Autocorrelation Function (ACF)



- Sample Autocorrelation Function (SACF)



Hypothesis Test for White Noise Process

Ljung-Box 검정 (Hypothesis Test)

- H_0: $\rho_1 = \rho_2 = \rho_3 \ldots = \rho_k = 0$ vs H_1: at least One $\rho_k \neq 0$

- Q-statistic at lag k: $Q_k = T(T+2)\sum_{j=1}^{k} \frac{\widehat{\rho_j^2}}{T-j}$

Gaussian White Noise Process

- $Y_t = \alpha + \beta X_t + Z_t$
- If $\{Z_t\}$ is white noise, correct
- If $\{Z_t\}$ is not white noise, $Z_t = \phi Z_{t-1} + \varepsilon_t$

대표적인 ar1 인 상황임,
한시점 전인 자신한테 영향을 받음 -> 공분산 0이 아님

- $Y_t - \alpha - \beta X_t = \phi(Y_{t-1} - \alpha - \beta X_{t-1}) + \varepsilon_t$
- $Re\text{-}estimate\, Y_t = \alpha(1-\phi) + \phi Y_{t-1} + \beta X_t - \phi\beta X_{t-1} + \varepsilon_t$

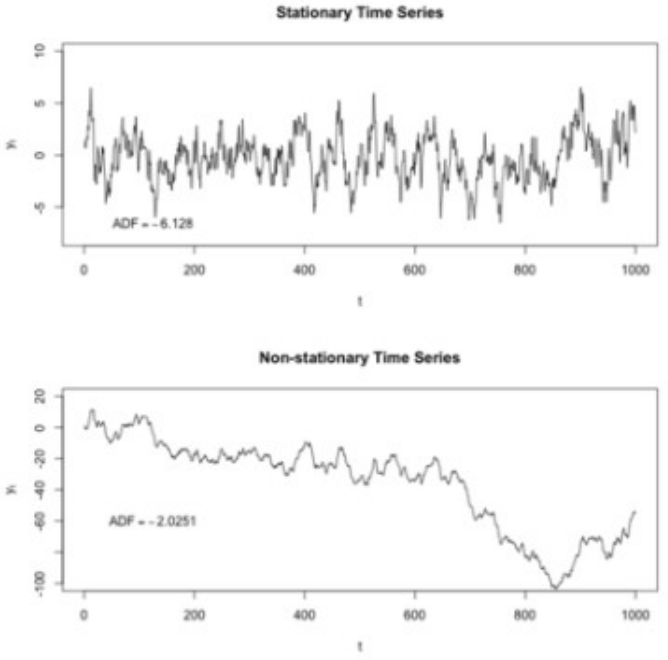
White Noise 실습

아래 지시에 따라 R로 백색잡음을 생성하고 특성을 확인해보자.

- set.seed(123)으로 고정 후, 평균 0, 표준편차 1인 정규분포에서 n=200 난수를 생성하여 시계열 객체로 만들어보자.
- 시계열 플롯, ACF, 히스토그램, Q-Q plot을 2×2 레이아웃으로 시각화해보자.
- Box.test()를 이용해 Ljung-Box 검정을 수행하고 결과를 해석해보자. (lag=10)
- 이번엔 AR(1) 구조 (arima.sim으로 φ=0.7)를 가진 시계열을 생성하고, 동일하게 Ljung-Box 검정을 수행해보자. 백색잡음과 결과가 어떻게 다른가?

Stationary Process

- 시간의 흐름 t와 상관 없이 기대값과 분산이 일정하며 일정 ACF ρ_k는 시간의 흐름 t와 상관 없이 두 시계열 간의 시간 간격 k에만 의존.
- Weak or Strong Stationarity
- Non-stationarity



비정상 시계열의 유형

유형	특징	예시	해결 방법
추세 비정상	평균이 시간에 따라 증가/감소	GDP, 주가	1차 차분 (d=1)
분산 비정상	변동 폭이 시간에 따라 변화	주식 변동성	로그 변환 후 차분
계절 비정상	특정 주기의 계절 패턴 반복	월별 판매량	계절 차분 (lag=m)

실습)

ts_air 데이터를 이용하여 정상화 과정을 단계별로 확인해보자.

1) 원 시계열 플롯을 보고 비정상인 이유 2가지를 말해보자.

2) log() 변환 후 플롯을 보고 무엇이 개선됐는지 설명해보자. log 변환 -> 변동성 줄어듬

3) diff(log(ts_air)) 후 플롯을 보고 정상 시계열의 특징을 확인해보자.

차분 -> 0근처에서 진동하는 정상 시계열 모형이 됨

4) 세 단계를 3×1 레이아웃으로 한 번에 시각화해보자.

ar1 이전시점의 내가 현재의 나를 설명
ar2는 이전+그 이전

ma 이전 시점의 오차

텍스트

Moving Average Process of Order1 :MA(1)

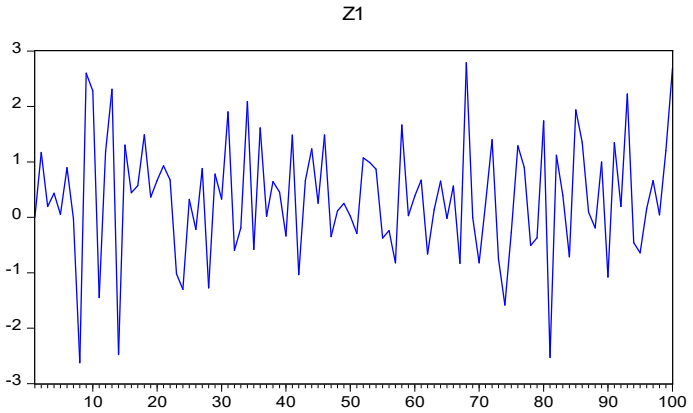
- $Z_t = \alpha + \varepsilon_t - \theta \cdot \varepsilon_{t-1} = \alpha + (1 - \theta B) \cdot \varepsilon_t, \{\varepsilon_t\}: i.i.d.N(0, \sigma^2)$

B = t-1
B2 =t-2

- $E[Z_t] = \alpha$
- $\gamma_0 = V[Z_t] =$
- $\gamma_1 =$ COV(Z_t, Z_(t-1)) = -theta sigma^2
- $\gamma_2 =$ 0, k>=2 면 감마k=0
- $\rho_1 = \gamma_1 / \gamma_0 =$
- $\rho_2 = \gamma_2 / \gamma_0 =$

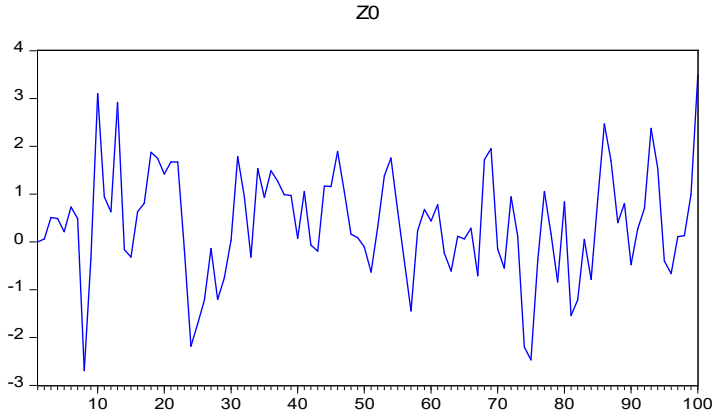
Moving Average Process of Order1 :MA(1)

$\theta > 0$



Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	-0.324	-0.324	52.754	0.000
		2	-0.068	-0.193	55.056	0.000
		3	0.006	-0.096	55.078	0.000
		4	-0.021	-0.076	55.299	0.000
		5	-0.047	-0.103	56.415	0.000
		6	0.025	-0.048	56.737	0.000
		7	0.048	0.024	57.915	0.000
		8	-0.073	-0.059	60.606	0.000
		9	0.071	0.035	63.187	0.000
		10	-0.032	-0.011	63.713	0.000
		11	0.037	0.044	64.396	0.000
		12	0.013	0.051	64.481	0.000

$\theta < 0$



Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	0.430	0.430	92.940	0.000
		2	-0.031	-0.266	93.438	0.000
		3	-0.076	0.073	96.353	0.000
		4	-0.093	-0.122	100.76	0.000
		5	-0.076	0.011	103.67	0.000
		6	0.006	0.027	103.69	0.000
		7	0.033	-0.005	104.25	0.000
		8	0.011	-0.005	104.31	0.000
		9	0.049	0.064	105.52	0.000
		10	0.044	-0.013	106.53	0.000
		11	0.042	0.058	107.42	0.000
		12	-0.002	-0.052	107.42	0.000

p-value가 커야 백색잡음이 아님
p-value =0 이면 백색잡음!!(porb)

자기회귀 모델(Autoregressive, AR)

- 과거 값들에 대한 회귀로 미래 값을 예측하는 방식

- AR(p):

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} \ldots + \phi_p y_{t-p} + \varepsilon_t$$

- ε_t: white noise

AR(1)의 계수에 대해 생각해보자.

$$y_t = 0.5 y_{t-1} + \varepsilon_t$$

파이가 1보다 작으면 ??
파이 = 0.5 -> 과거값이 현재값에 반만큼 적용.
1보다 크면 과거가 더 영향
1보다 작으면 과거 영향 작음

자기회귀 모델(Autoregressive, AR)

- 정상성이란?
- 시계열의 평균, 분산, 자기상관 구조가 시간에 따라 변하지 않는 상태
- AR(1) 모형에서 정상성이 성립하려면 ϕ_1의 절댓값이 1 미만이어야 함
  - $|\phi_1| < 1$ 이면?
  - $|\phi_1| \geq 1$ 이면?

파이=1 대표적 비정상적인 시계열

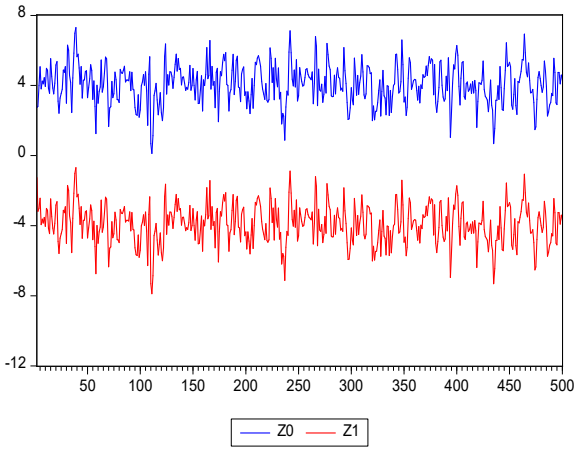
Autoregressive Process of Order 1:AR(1)

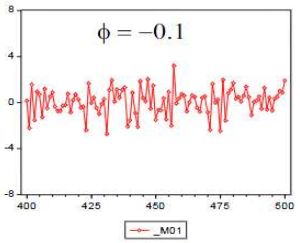
- $Z_t = \alpha + \beta \cdot Z_{t-1} + \varepsilon_t, \{\varepsilon_t\}: i.i.d. N(0, \sigma^2)$ => AR1
- $Z_t - \mu = \beta \cdot (Z_{t-1} - \mu) + \varepsilon_t$

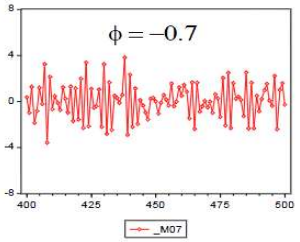
Autoregressive Process of Order 1:AR(1)

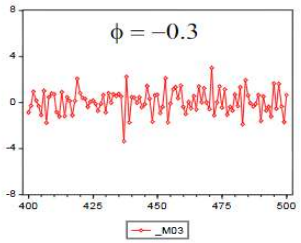
$Z_0: \mu > 0$ $Z_1: \mu < 0$

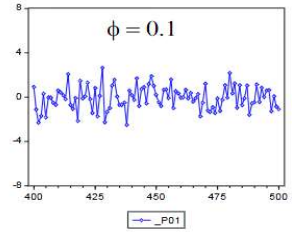
$$Z_t - \mu = \phi(Z_{t-1} - \mu) + \varepsilon_t$$

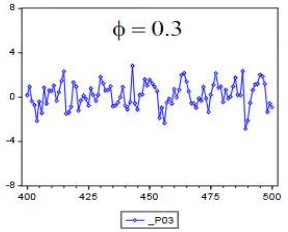


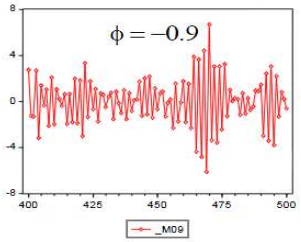


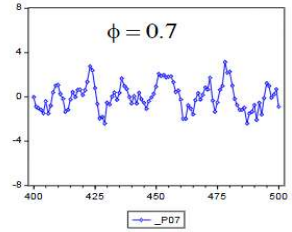


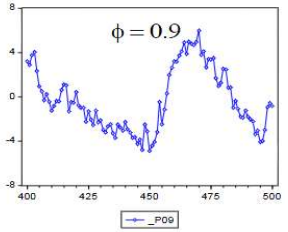












ACF of AR(1) in MA representation

$$Z_t - \phi \cdot Z_{t-1} = \varepsilon_t$$

$$Z_t = (1 - \phi B)^{-1} \varepsilon_t$$

$$Z_t = (1 + \phi B + \phi^2 B^2 + \cdots) \varepsilon_t$$

무한한 과거 오차항의 합으로 나타낼 수 있음

$$Z_t - \phi \cdot Z_{t-1} = \varepsilon_t$$

$$Z_{t-1} - \phi \cdot Z_{t-2} = \varepsilon_{t-1}$$

$$Z_{t-2} - \phi \cdot Z_{t-3} = \varepsilon_{t-2}$$

....

ACF of AR(1) in AR representation

- $Z_t = \phi \cdot Z_{t-1} + \varepsilon_t$

- $(1 - \phi B)\rho_k = 0$