시계열분석

4주차: 기초 분석 기법

데이터 평활

- 시계열 데이터에서 단기 변동(노이즈)을 줄이고, 전반적인 패턴(추세·계절성)을 부드럽게 표현

- 목적: 측정의 오류, 높게 튀는 측정치를 제거하기 위해 이동평균 사용

- 장점: 패턴 파악 용이, 이상값(Outlier)에 대한 민감도 감소
- 단점: 과도한 평활 시 중요한 세부 변동 정보 손실

이동평균 (Moving Average)

- 이동평균(Moving Average):
  - 고정된 구간(윈도우 k) 내 값들의 평균으로 현재 값을 대체
  - k가 클수록 → 더 부드러운 곡선, 하지만 최신 변화에 늦게 반응
  - k가 작을수록 → 노이즈가 많지만 변화에 빠르게 반응

윈도우 크기(k)	장점	단점	적합한 상황
k = 3	변화 빠르게 반영	노이즈 많음	단기 변동 탐지
k = 7	균형 잡힌 평활	약간의 지연	일반적 시계열
k = 12	장기 추세 명확	세부 변동 손실	월별 계절성 제거

이동평균 - 실습

zoo 패키지 필요

rollmean(data, k = 10, fill = 0, align = “center”)

- k: 윈도우 크기
- fill: 윈도우가 채워지지 않는 구간에 할당할 값. (NA가 기본값)
- align: 해당 시점의 정렬
  - “align="right“ → 과거 k개 평균 (예측 상황에 적합)
  - align="center“ → 앞뒤 포함 (분석·시각화에 적합)
  - align="left“ → 미래 k개 평균 (예측 분석에는 부적합)

이동평균 – 실습 함께하기

zoo 패키지 필요

Lec4_AirPassengers.csv 데이터를 불러와 setnames() 함수를 이용하여 Date 와 Passengers 이름을 지정해보자.

```
air <- fread("Lec4_AirPassengers.csv")
setnames(air, c("V1", "V2"), c("Date", "Passengers"))
```

```
> head(air)
         V1    V2
     <char> <int>
1: 1949-01   112
2: 1949-02   118
3: 1949-03   132
4: 1949-04   129
5: 1949-05   121
6: 1949-06   135
```

```
> head(air)
      Date Passengers
    <char>      <int>
1: 1949-01        112
2: 1949-02        118
3: 1949-03        132
4: 1949-04        129
5: 1949-05        121
6: 1949-06        135
```

이동평균 – 실습 함께하기

zoo 패키지 필요

윈도우 사이즈가 7인 이동평균 값을 구해보자. 이 때, 정렬은 오른쪽으로 설정해보자.

```
air[, ma_7 := rollmean(Passengers, k = 7, fill = NA, align = "right")]
```

```
> head(air, 20)
       Date Passengers     ma_7
     <char>      <int>    <num>
 1: 1949-01        112       NA
 2: 1949-02        118       NA
 3: 1949-03        132       NA
 4: 1949-04        129       NA
 5: 1949-05        121       NA
 6: 1949-06        135       NA
 7: 1949-07        148 127.8571
 8: 1949-08        148 133.0000
 9: 1949-09        136 135.5714
10: 1949-10        119 133.7143
11: 1949-11        104 130.1429
12: 1949-12        118 129.7143
13: 1950-01        115 126.8571
14: 1950-02        126 123.7143
15: 1950-03        141 122.7143
16: 1950-04        135 122.5714
17: 1950-05        125 123.4286
18: 1950-06        149 129.8571
19: 1950-07        170 137.2857
20: 1950-08        170 145.1429
```

이동평균 – 실습 각자하기

zoo 패키지 필요

AirPassengers 데이터에 k=3, k=7, k=12 이동평균을 각각 구하고 그래프로 비교해보자. align은 'right'로 통일한다.

이동평균 – 시각화 실습

ggplot2 패키지 필요

앞에서 계산한 ma_3, ma_7, ma_12를 하나의 그래프에 겹쳐서 그려보자. 각 선의 색을 다르게 지정하고 범례를 추가해보자.

지수평활 (Exponential Smoothing)

- 지수평활(Exponential Smoothing): 최근 데이터에 더 큰 가중치(α) 부여
  - 단순 지수평활(SES), Holt(추세), Holt-Winters(계절성) 등 확장 버전 존재

$$\hat{y}_t = \alpha y_{t-1} + (1-\alpha)\hat{y}_{t-1}$$

α: 0~1 사이의 평활계수

- α (알파): 0~1 사이의 평활 계수
  - αα가 1에 가까울수록 → 최근 데이터를 거의 그대로 반영 (노이즈에 민감)
  - αα가 0에 가까울수록 → 과거 예측값에 크게 의존 (변화에 둔감)

지수평활 (Exponential Smoothing)

α 값	최근 반영 비중	과거 반영 비중	특징
α = 0.1	10%	90%	매우 부드러운 평활
α = 0.3	30%	70%	일반적으로 많이 사용
α = 0.9	90%	10%	빠른 반응, 노이즈 많음

- SES 확장 버전

  - SES (Simple Exponential Smoothing): 추세·계절성 없는 데이터
  - Holt: 추세(Trend) 있는 데이터에 추가 계수 β 사용
  - Holt-Winters: 추세 + 계절성(Seasonality)까지 처리, 계수 γ 추가

지수평활 – 실습 함께하기

forecast 패키지 필요

ses(data, h = 10, alpha = 0.3, initial = “simple”)

- h: 예측하고자 하는 미래 시점 개수 (기본값=10)
- alpha: 평활계수, NULL 이면 함수를 통해 최적의 계수 추정
- initial: 초기값 설정 방법
  - “optimal”: 초차 최소화 기준으로 추정 (기본값)
  - “simple”: 첫 관측값을 초기값으로 사용 (전통적인 SES 접근)

accuracy(model): 예측력을 보는 함수

- ME RMSE MAE MPE MAPE MASE ACF1

지수평활 – 실습 함께하기

forecast 패키지 필요

앞 데이터의 Passengers 변수만 가져와 ts() 함수로 월별 데이터를 생성해보자.

```
ts_air <- ts(air$Passengers, frequency = 12, start = c(1949, 1))
```

지수평활 계수가 0.3인 지수평활 기법으로 1961년 1월부터 12월까지 월별 예측값을 만들어보자.
초기 값은 첫 관측치로 설정해보자.

```
ses(ts_air, h=12, alpha=0.3, initial="simple")
```

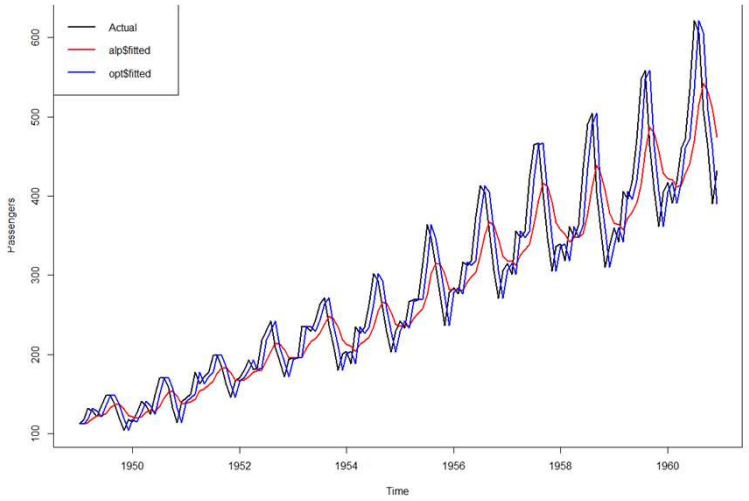
지수평활 계수를 최적으로 설정하였을 때와 비교했을 때, 어떤 것이 정확도가 좋은가?

지수평활 – 실습 함께하기

forecast 패키지 필요

그래프로 나타내보자.

```
plot(ts_air, type = "l", lwd = 2, xlab = "Time", ylab = "Passengers")
lines(alp$fitted, col = "red", lwd = 2)
lines(opt$fitted, col = "blue", lwd = 2)
legend("topleft", legend = c("Actual", “a=0.3”, “a=fitted”), col = c("black", "red", "blue"), lty = 1, lwd = 2)
```



지수평활 – 실습 각자하기

forecast 패키지 필요

α = 0.1, 0.3, 0.9 세 가지로 SES를 적용한 뒤 accuracy()로 정확도를 비교해보자. 초기값은 첫 관측치로 설정한다(initial='simple').

지수평활 – 시각화 실습

ggplot2 패키지 필요

α=0.1, 0.3, 0.9 예측값(fitted)과 실제값을 하나의 그래프로 비교해보자. 이후, α를 NULL로 설정한 최적 모델(opt)과도 비교해보자.

생각해보기!

- α=0.9 선이 실제값에 가장 가깝게 따라가는 이유는?
- 추세가 있는 AirPassengers에 SES가 적합하지 않은 이유를 생각해보자

평활 예시 – 손으로 풀어보기

아래는 각 시점별 $\hat{y}_t$을 표로 정리한 것이다. 윈도우 크기가 3인 이동평균 예측 값과 평활계수가 0.3인 예측 값을 계산해보자.

시점(t)	실제값	이동평균 예측값	지수평활 예측값
1	10		
2	12		
3	11		
4	13		
5	15		
6	14		
7	?		

4주차 과제

- “Lec2_UNRATE.csv” 데이터를 활용하여 eclass 내 4주차 과제 #1을 풀어보자.

시계열에 특화된 탐색법

- 정상성(stationarity): 시계열이 정상성을 가진다는 것은, 시간의 흐름에 따라 확률적 성질(평균, 분산, 자기상관 구조 등)이 변하지 않는다는 의미
  - 특정 시점의 데이터 분포가, 전체적으로 언제 측정하더라도 동일한 분포를 가짐

- 자기상관(self correlation 또는 aurocorrelation): 시계열이 스스로 다른 시점과 상관을 갖는다는 의미
  - "오늘의 주가"가 "어제 주가"와 얼마나 관련이 있는지(1시차) 등

- 허위상관(spurious correlation): 실제로는 인과관계나 상호작용이 없는데, 통계적으로 높은 상관계수가 관측되는 상황
  - 아이스크림 판매량과 상어 공격 건수가 같은 시기에 비슷하게 증가한다고 해서, 두 현상 사이에 직접적 인과관계가 있다고 볼 수 없음

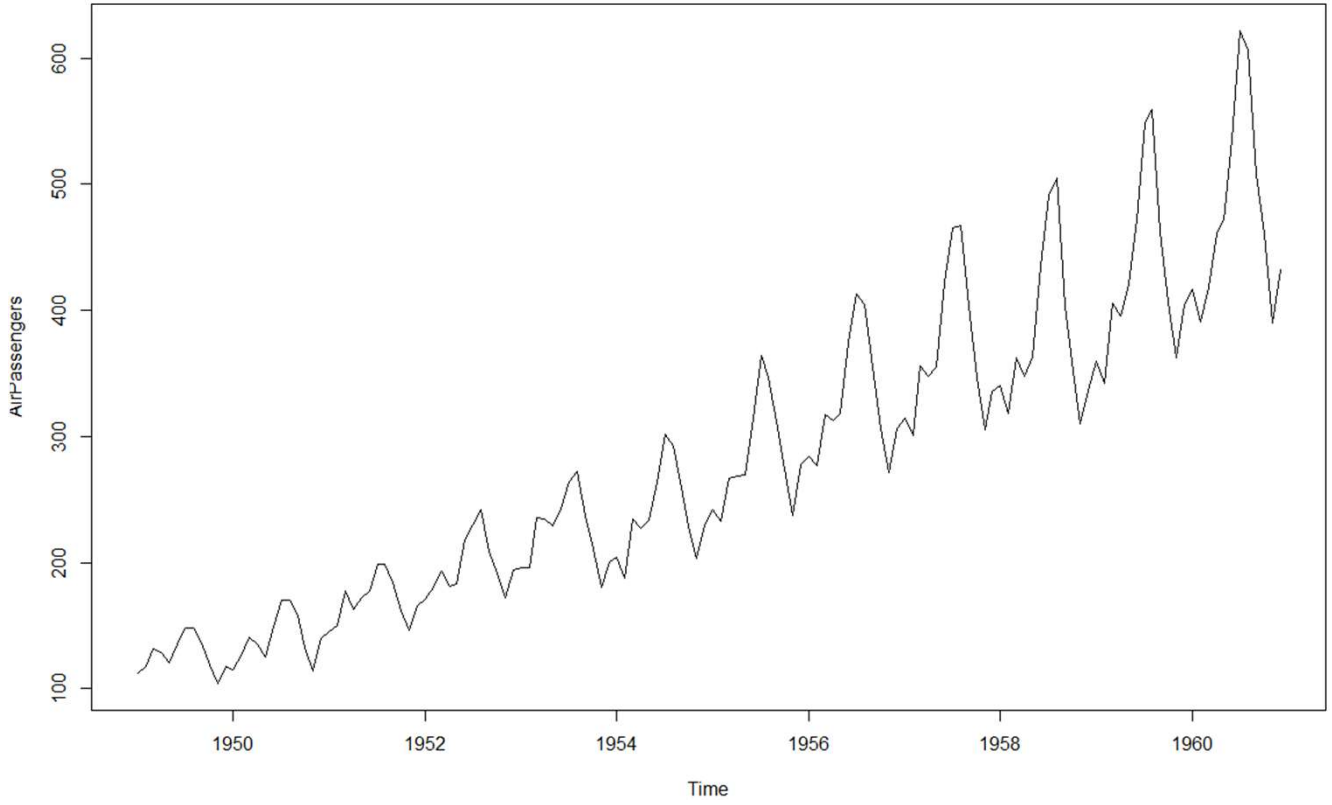
정상성(Stationarity) 개념 정리

구분	평균	분산	예시
정상 (Stationary)	일정	일정	백색잡음 (White Noise)
비정상 (Non-stationary)	시간에 따라 변함	시간에 따라 변함	주가, 항공 승객수

- 비정상 → 정상으로 변환하는 방법 2가지:
  - 로그 변환 (log): 분산이 시간에 따라 커질 때 사용
  - 차분 (diff): 평균이 시간에 따라 변할 때 사용

정상성(Stationarity)

- 데이터의 흐름이 정상인가?



ADF 검정 (Augmented Dickey-Fuller)

- ADF 검정이란?

  - 시계열에 단위근(Unit Root)이 있는지 통계적으로 검정

  - 단위근이 있다 = 비정상 시계열 (랜덤 워크처럼 끝없이 떠돎)

H0 (귀무가설): 단위근이 존재한다 → 비정상 시계열

H1 (대립가설): 단위근이 없다 → 정상 시계열

- ADF 검정 절차 (단계별)
- 1단계: 원본 데이터에 adf.test() 실행
- 2단계: p-value ≥ 0.05 이면 → 로그 변환 후 재검정
- 3단계: 여전히 비정상이면 → 계절 차분 diff(..., 12) 후 재검정
- 4단계: 여전히 비정상이면 → 1차 차분 diff() 후 재검정
- 5단계: p-value < 0.05 확인 → 정상 시계열 확보 완료

ADF 검정 (Augmented Dickey-Fuller)

- ADF 검정 절차:

```
library(tseries)
adf.test(ts_data)
```

- 하지만, 그 전에 로그변환과 차분을 해야함:

```
log(data) #로그 변환
diff(data, 12) # 12개월 간격 차분(계절 차분)
diff(data) # 1차 차분
```

ADF 검정 (Augmented Dickey-Fuller) - 실습

tseries 패키지 필요

AirPassengers 데이터를 단계적으로 변환(로그→계절차분→1차차분)하고 각 단계에서 ADF 검정을 실시해보자.

4주차 과제 #2

- “Lec2_UNRATE.csv” 데이터를 활용하여 eclass 내 4주차 과제 #2를 풀어보자.