데이터사이언스

Lecture 13 선형회귀분석

회귀분석 (Regression Analysis) 도입

변수 간 관계를 수식으로 표현하여 예측에 활용한다.

01
관계 파악

변수 X가 Y에 어떤 영향을 미치는가?
방향과 크기를 정량화한다.

02
예측

X 값이 주어졌을 때
Y 값을 추정한다.

03
통제 변수 효과

다른 변수를 통제한 상태에서
특정 변수의 순효과를 본다.

Y 변수 형태에 따른 회귀 종류

Y 변수 형태	회귀 종류	예시
연속형 (수치)	선형회귀 (Linear)	키 → 몸무게, 광고비 → 매출
이진형 (0/1)	로지스틱 회귀 (Logistic)	흡연 → 폐암 발병 여부
다중 클래스	다항 로지스틱 회귀	고객 → 상품군 분류
카운트	포아송 회귀	지역 → 사고 발생 횟수

단순선형회귀 (Simple Linear Regression)

모집단 모형: $Y = \beta_0 + \beta_1 X + \varepsilon$ **추정 회귀식:** $\hat{Y} = \hat{\beta_0} + \hat{\beta_1} X$

회귀계수의 의미

- β_0 (절편): X=0일 때의 Y 값
- β_1 (기울기): X가 1 증가할 때 Y의 평균 변화량
- ε (오차항): $\varepsilon \sim N(0, \sigma^2)$ 가정
- 잔차 $e_i = y_i - \hat{y}_i$: 실제값과 예측값의 차이

최소제곱법 (Ordinary Least Squares, OLS)

잔차제곱합(SSE)을 최소화하는 $\hat{\beta}_0, \hat{\beta}_1$을 찾는 방법

$$\min \sum (y_i - \hat{\beta_0} - \hat{\beta_1} x_i)^2$$

→ 잔차가 가장 작은 직선이 최적 회귀선

OLS 추정량 (닫힌 해)

$$\hat{\beta_1} = \Sigma(x_i - \bar{x})(y_i - \bar{y}) \,/\, \Sigma(x_i - \bar{x})^2$$

$$\hat{\beta_0} = \bar{y} - \hat{\beta_1} \cdot \bar{x}$$

```
import statsmodels.formula.api as smf

model = smf.ols(
    '매출 ~ 광고비', data=df).fit()

print(model.summary())
```

예제 ① 단순선형회귀 — 나이 → 콜레스테롤

문제
나이를 독립변수로 콜레스테롤을 예측하는 단순선형회귀를 적합하고,
회귀식, R^2, p-value를 출력한 뒤 산점도에 회귀선을 그려보세요.

```
import statsmodels.formula.api as smf

# 회귀 적합
model = smf.ols('콜레스테롤 ~ 나이', data=df).fit()
print(model.summary())

# 시각화
plt.figure(figsize=(8, 5))
plt.scatter(df['나이'], df['콜레스테롤'], alpha=0.5, color='steelblue')
plt.plot(df['나이'], model.fittedvalues, color='red', lw=2)
plt.xlabel('나이'); plt.ylabel('콜레스테롤')
plt.title(f'R² = {model.rsquared:.3f}')
plt.show()
```

회귀분석 도구 선택 — sklearn vs statsmodels

같은 회귀분석이라도 목적에 따라 사용하는 라이브러리가 다르다.

	sklearn	statsmodels
주 목적	예측 (Prediction)	추론·해석 (Inference)
출력 정보	계수, 절편, R^2 (간결)	계수, t-value, p-value, 신뢰구간, F-검정 등 (풍부)
ANOVA 테이블	직접 제공 X	anova_lm() 함수로 즉시 출력
summary() 메서드	없음	있음 (모든 통계량 한 번에)
함수 호출 방식	`LinearRegression().fit(X,y)`	`smf.ols('y~x', data=df).fit()`
추천 상황	ML 파이프라인, 교차검증, 예측 중심	통계적 해석, 보고서, 논문, 가설검정

오늘은 statsmodels로 진행한다

회귀계수의 유의성 검정, ANOVA 테이블, R^2 등 통계적 해석에 집중하기 때문이다.

statsmodels summary() — 한 줄씩 읽기

model.summary() 출력의 각 항목을 정확하게 해석할 수 있어야 한다.

model.summary() 예시 출력

```
                OLS Regression Results
==========================================
Dep. Variable:         매출      R-squared:    0.842
Model:                 OLS       Adj. R-squared: 0.838
No. Observations:      100       F-statistic:    258.6
Df Residuals:           98       Prob(F-stat):  1.2e-38
==========================================
             coef    std err      t    P>|t|
------------------------------------------
Intercept   45.21     3.812    11.86   0.000
광고비       1.503    0.094    16.02   0.000
==========================================
```

핵심 항목 해석

R-squared
모델이 설명하는 분산 비율 (0~1, 클수록 좋음)

Adj. R-squared
변수 개수 보정한 R^2 (다중회귀에서 비교)

F-statistic / Prob(F)
회귀 전체가 유의한가? p<0.05면 유의

coef
추정된 회귀계수 ($\hat{\beta}$)

std err
계수의 표준오차 — 추정 정밀도

t / P>|t|
각 계수가 0과 다른가? p<0.05면 유의

분산 분해 — SST = SSR + SSE

관측값의 총 변동을 모델이 설명하는 부분과 설명하지 못하는 부분으로 분해한다.

$$SST = SSR + SSE$$

SST

Total Sum of Squares

$$\Sigma (y_i - \bar{y})^2$$

전체 변동
(평균 대비 관측값의 흩어짐)

SSR

Regression Sum of Squares

$$\Sigma (\hat{y}_i - \bar{y})^2$$

회귀로 설명되는 변동
(예측값이 평균에서 떨어진 정도)

SSE

Error Sum of Squares

$$\Sigma (y_i - \hat{y}_i)^2$$

회귀로 설명되지 못하는 변동
(잔차 = 실제 − 예측)

회귀 ANOVA 테이블

요인	제곱합	자유도	평균제곱	F
회귀	SSR	k	MSR = SSR/k	**MSR / MSE**
잔차	SSE	n−k−1	MSE = SSE/(n−k−1)	
전체	SST	n−1		

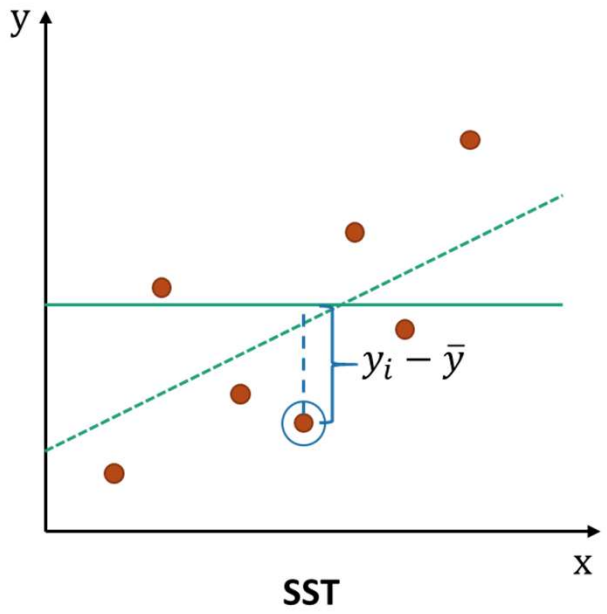
결정계수 R^2 (Coefficient of Determination)

$$R^2 = SSR / SST = 1 - SSE / SST$$

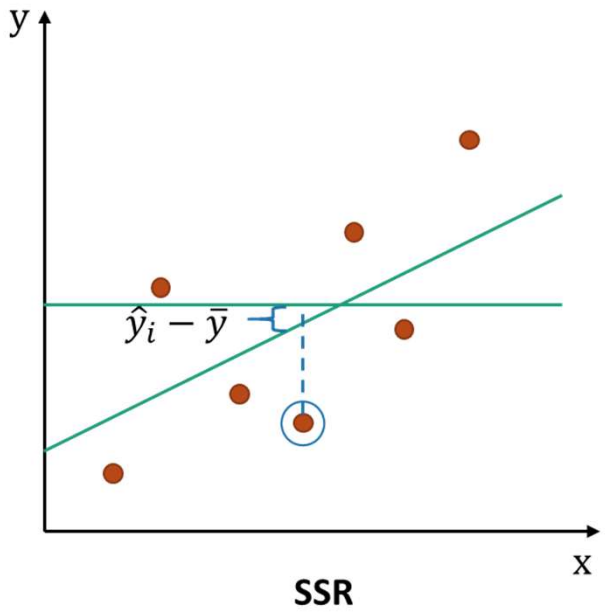
$0 \le R^2 \le 1$ 1에 가까울수록 설명력↑
R^2=0.21 → 모델이 Y 분산의 21%를 설명

회귀모형의 유의성

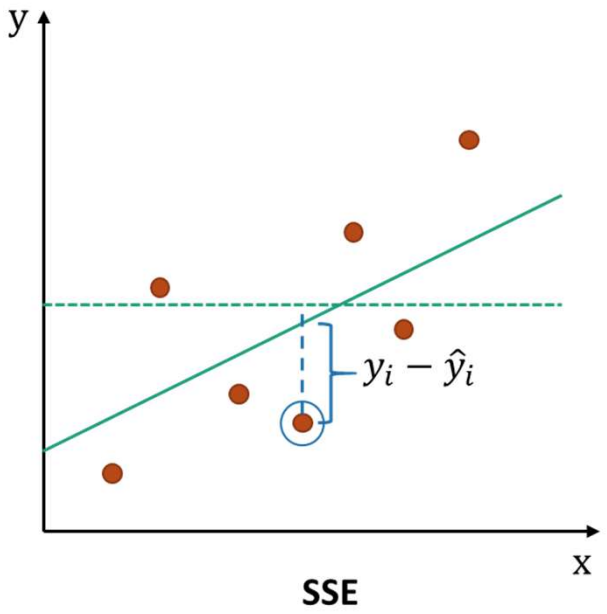
- $SST = SSR + SSE$
- SST(Total sum of squares): 전체제곱합 $\sum_{i=1}^{n}(y_i - \bar{y})^2$
- SSR(Regression sum of squares): 회귀제곱합 $\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2$
- SSE(Error sum of squares): 오차제곱합 $\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$



SST



SSR



SSE

다중선형회귀 (Multiple Linear Regression)

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_k X_k + \varepsilon$$

주요 평가 지표

지표	의미
R²	모델이 설명하는 분산의 비율 (0~1)
adj R²	변수 개수를 보정한 R²
RMSE	예측 오차의 표준편차 (단위 동일)
p-value	각 계수의 통계적 유의성
VIF	다중공선성 진단 (>10 위험)

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

$$\text{Adjusted } R^2 = 1 - \frac{(1-R^2)(n-1)}{n-k-1}, k\text{: 독립변수 수}$$

```python
import statsmodels.formula.api as smf
import statsmodels.api as sm

# 공식 표기로 직관적
model = smf.ols(
    '매출 ~ 광고비 + 직원수 + 지점수',
    data=df).fit()

# 회귀 요약
print(model.summary())

# ANOVA 테이블
print(sm.stats.anova_lm(model))
```

예제 ② 다중선형회귀 + ANOVA 테이블

문제
나이·BMI·혈압을 독립변수로 콜레스테롤을 예측하는 다중회귀를 적합하고,
summary와 ANOVA 테이블을 출력한 뒤 각 변수의 유의성을 해석하세요.

```
import statsmodels.api as sm

# 다중회귀 적합
model = smf.ols(
    '콜레스테롤 ~ 나이 + BMI + 혈압', data=df).fit()

# 회귀 요약 (계수·p-value·R²)
print(model.summary())

# ANOVA 테이블 (각 변수의 SS, F, p)
print(sm.stats.anova_lm(model, typ=2))
```

회귀 진단 (Regression Diagnostics)

회귀모델이 신뢰할 만한지 4가지 가정을 점검해야 한다.

① 선형성

X와 Y가 선형 관계인가?
→ 잔차 vs 적합값 산점도 (**패턴 없어야**)

plt.scatter(fitted, resid)

② 정규성

잔차가 정규분포를 따르는가?
→ 잔차의 QQ-plot, Shapiro-Wilk **p > 0.05**

sm.qqplot(resid)
stats.shapiro(resid)

③ 독립성

잔차들이 서로 독립인가?
→ Durbin-Watson (**1.5~2.5 정상**)

durbin_watson(resid)

④ 등분산성

잔차의 분산이 일정한가?
→ Breusch-Pagan 검정 **p > 0.05**

het_breuschpagan(resid, exog)

13주차 과제

week13_health.csv 데이터를 이용하여 e-Class 과제를 푸세요. (encoding='cp949')

변수	설명
환자ID	고유 번호
나이	환자 나이 (세)
BMI	체질량지수 (kg/m²)
혈압	수축기 혈압 (mmHg)
콜레스테롤	총 콜레스테롤 (mg/dL)
성별 / 흡연 / 운동	남/여, Y/N, Y/N
진단	건강 / 주의 / 위험 (3 클래스)
당뇨여부	0 / 1 (이진)