데이터사이언스

Lecture 14 실전분석

연습문제

week14_data.csv 파일은 데이터사이언스 전공 학부생 100명의 한 학기 학업·만족도 자료이다. 변수 설명은 다음과 같다.

변수명	타입	설명 (범위)
student_id	문자	학생 고유 ID
gender	범주(2)	남 / 여
major	범주(3)	데이터사이언스 / 통계 / 컴퓨터공학
study_method	범주(3)	강의만 / 강의+실습 / 강의+실습+과제
video_watched	범주(2)	Y / N (보충영상 시청 여부)
intern_experience	범주(2)	있음 / 없음 (인턴 경험)
midterm	실수	57.0 ~ 99.6
final	실수	60.1 ~ 100.0
satisfaction_begin	정수 1~10	2 ~ 10
satisfaction_end	정수 1~10	3 ~ 10

종합 과제 – 학생 학업 성취도 예측

과제 개요:

이번 과제의 목표는 한 학기 동안 배운 도구들(EDA·결측치 처리·정규화·가설검정·회귀분석)을 하나의 실제 분석 문제에 모두 적용해 보는 것입니다. 데이터는 가상의 학생 200명의 학업·생활 정보예요. 여러분의 미션은 'final_score(기말 점수)를 가장 잘 예측하는 회귀 모델을 만드는 것' 입니다.

학습 목표:

- **결측치·이상치를 발견하고 적절히 처리할 수 있는가**
- **정규성을 진단하고 필요한 변환(로그 등)을 적용할 수 있는가**
- **상황에 맞는 가설검정(t-검정, ANOVA, 카이제곱)을 골라 쓸 수 있는가**
- **단순·다중 회귀모델을 적합하고 결과를 해석할 수 있는가**
- **회귀 진단(잔차의 정규성·등분산성·독립성)을 수행**

종합 과제 – 학생 학업 성취도 예측

데이터 설명:

식별자·인구통계

변수명	타입	설명
student_id	문자	학생 고유 ID (ST0001 ~ ST0200)
gender	범주(2)	성별 — M(남) / F(여)
major	범주(4)	전공 — data_science / statistics / computer_science / math
year	정수	학년 (1~4)

학업·생활 변수 (수치형 5개)

변수명	단위	범위	설명
prev_gpa	학점	1.99 ~ 4.30	직전 학기 평점 (4.5 만점 기준)
study_hours	시간/주	0.5 ~ 60	주당 평균 공부 시간
sleep_hours	시간/일	결측 12개	평균 수면 시간 (일부 결측)
absences	횟수	0 ~ 9	학기 중 결석 횟수
commute_min	분	결측 8개	편도 통학 시간 (일부 결측)

종합 과제 – 학생 학업 성취도 예측

데이터 설명:

환경 변수 (범주형 3개)

변수명	범주	값
part_time_job	2	아르바이트 — yes / no
study_group	2	스터디 그룹 참여 — yes / no
scholarship	3	장학금 — full / partial / none

종속변수 (Y변수)

변수명	타입	범위	설명
final_score	수치 (연속형)	37.3 ~ 90.6	기말고사 점수 (예측 대상)

STEP 1. EDA — 데이터 구조와 분포 탐색

데이터의 기본 구조와 변수별 분포를 파악하라. 결측치 위치도 함께 확인한다.

해야 할 일:

① df.shape, df.info(), df.dtypes로 변수 타입과 행/열 수 확인

② df.describe()로 수치형 변수의 요약 통계량 출력

③ df.isnull().sum()으로 결측치 개수 확인 — 어느 변수에 몇 개?

④ 수치형 변수의 히스토그램(또는 박스플롯)을 그려 분포 모양 관찰

⑤ 범주형 변수의 빈도표(value_counts) 확인

STEP 2. 결측치·이상치 처리

STEP 1에서 발견한 결측치를 처리하고, study_hours에서 의심스러운 이상치를 찾아 처리하라.

해야 할 일:

① 결측치 처리 방법 선택 — dropna() / fillna(평균) / fillna(중앙값) 중 어떤 것? 이유와 함께

② study_hours의 박스플롯을 그리거나 describe()로 이상치 확인 (Q3 + 1.5×IQR 기준)

③ 이상치를 어떻게 처리할지 결정 — 제거 / 그대로 둠 / 윈저화 — 이유 명시

④ 처리 후의 df 행 수와 변경된 분포 요약

STEP 3. 정규성 검정 및 정규화

수치형 변수 6개에 대해 정규성 검정을 실시하고, 위배된 변수에 로그 변환을 적용한 후 효과를 확인하라.

해야 할 일:

① 각 수치형 변수에 stats.shapiro() 적용. p > 0.05면 정규성 만족, p < 0.05면 위배

② QQ-plot이나 히스토그램으로 시각적으로도 확인

③ 정규성 위배 변수에 np.log1p() 변환을 적용 (예: log_study_hours = np.log1p(study_hours))

④ 변환 후의 왜도(skew)와 Shapiro p값이 어떻게 바뀌었는지 비교 표 작성

STEP 4. 가설검정 — 그룹간 final_score 차이 탐색

범주형 변수에 따라 final_score 평균에 차이가 있는지 적절한 검정으로 확인하라. 최소 3가지 검정을 사용해야 함.

해야 할 일 (최소 3개):

① 독립표본 t-검정: study_group(yes/no) → final_score 차이가 있는가? (Levene 검정으로 등분산 먼저 확인)

② ANOVA + Tukey HSD: scholarship(3그룹) → final_score 평균이 다른가? ANOVA 유의하면 사후검정도 실시

③ 카이제곱 검정: scholarship × study_group이 독립인가? (이건 두 범주형 변수의 관계 검정)

④ 추가로 본인이 흥미롭다고 생각하는 검정을 한 가지 더 수행해도 좋음 (보너스)

STEP 5. 단순 회귀분석 — prev_gpa로 final_score

직전 학기 평점(prev_gpa) 하나로 final_score를 예측하는 단순선형회귀 모델을 적합하라.

해야 할 일:

① smf.ols('final_score ~ prev_gpa', data=df).fit()로 모델 학습

② model.summary() 출력 — 회귀계수(β0, β1), R^2, F p-value, prev_gpa의 t·p값 해석

③ 산점도 + 회귀선 그리기 — '관측값 vs 회귀선'을 시각적으로 확인

④ 회귀식을 자연어로 해석 — 'GPA가 1점 오르면 final_score가 몇 점 변화'?

STEP 6. 다중 회귀분석 — 전체 변수 사용

STEP 3에서 변환한 로그 변수와 범주형 변수를 모두 포함한 다중회귀 모델을 적

해야 할 일:

① 다중회귀 적합

② R^2와 Adj. R^2를 STEP 5의 단순회귀와 비교 — 얼마나 향상됐나?

③ 유의한 변수($p < 0.05$)만 골라 표로 정리 — 변수명·coef·p-value

④ 가장 영향력 큰 변수 3개를 꼽고, 각각의 효과를 자연어로 설명

⑤ 유의하지 않은 변수도 짚고 — 왜 유의하지 않은지 추측

STEP 7. 회귀 진단 — 잔차 분석

STEP 6에서 적합한 다중회귀 모델의 4가지 가정(LINE)을 진단하라.

해야 할 일:

① Linearity (선형성): 잔차 vs 적합값 산점도. 패턴 없이 무작위로 흩어져야 함

② Independence (독립성): Durbin-Watson 통계량 (1.5~2.5면 OK)

③ Normality (정규성): 잔차에 Shapiro-Wilk + QQ-plot

④ Equal variance (등분산성): Breusch-Pagan 검정 (p > 0.05면