데이터사이언스

Lecture 03 데이터 분석적 사고방식과 데이터 모델링의 이해

데이터 필수 시대

- 데이터(Data)
  - 어떤 변수가 가질 수 있는 다양한 가능성 중의 하나가 현실 세계에 구체화된 값으로 이론을 세우는 기초가 되는 사실 또는 바탕이 되는 자료를 의미
  - 다양한 데이터 생성 인프라를 통해 생성된 데이터에서 유용한 정보와 지식을 추출해 내는 데이터 사이언스 학문이 등장

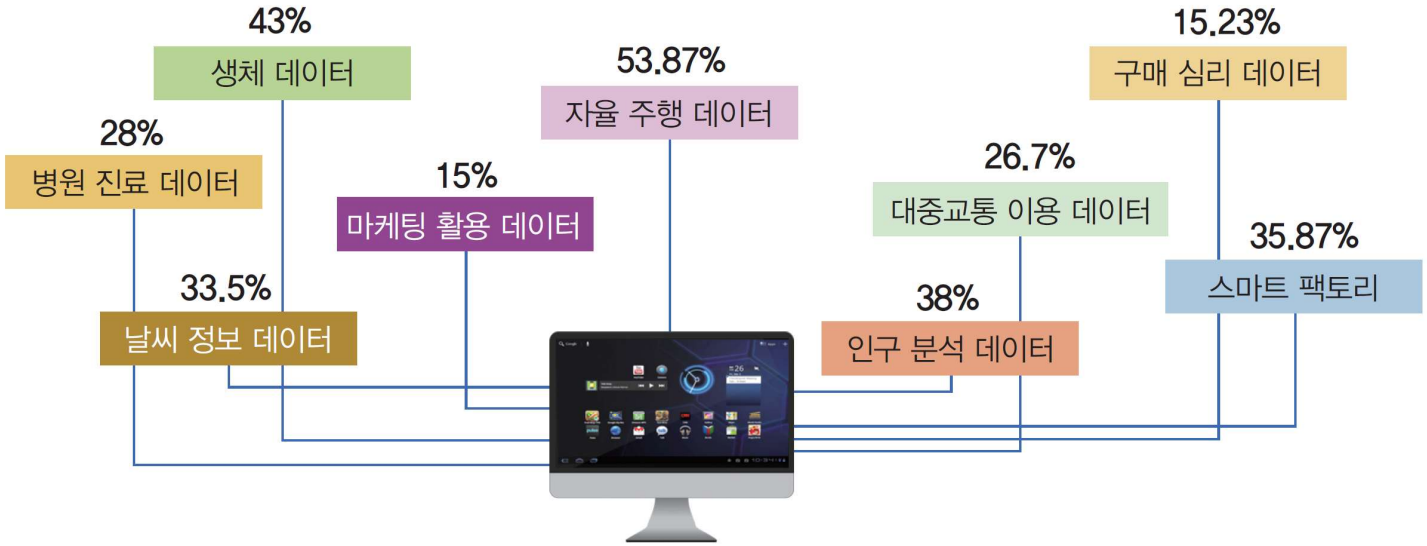


그림 1-1 데이터 생성 인프라

데이터 사이언스 로드맵

- 4차 산업혁명
  - 사이버 물리 시스템과 사물인터넷의 기술 융합으로 새로운 가치를 창출하고 있는 시대
  - 4차 산업혁명의 시대적 환경에서 데이터 사이언스 영역에 대한 학습을 전개하기 위한 로드맵 제시

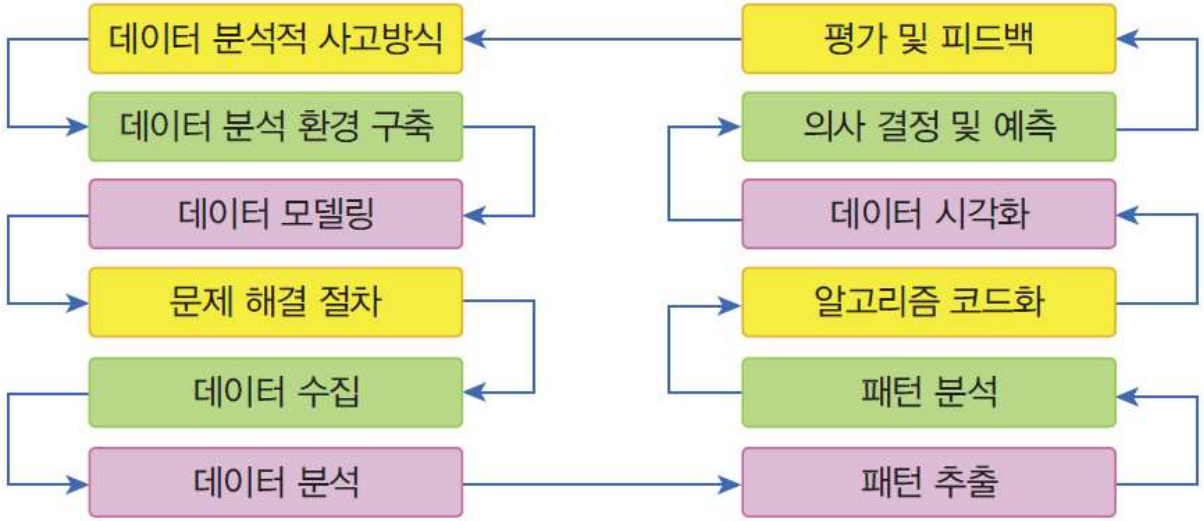


그림 1-2 데이터 사이언스 학습 로드맵

데이터가 제공하는 무한한 기회

◦ 데이터 활용도의 존재가치

- 실시간으로 수집되는 빅데이터는 향후 미래를 예측하기 위한 기준 척도로 활용



그림 1-3 4차 산업혁명 시대의 데이터를 활용한 스마트 팩토리 구축

정형 데이터와 비정형 데이터

◦ 데이터의 종류

- 정형 데이터와 비정형 데이터로 구분되며 정형 데이터를 비정형 데이터로 변환도 가능



그림 1-4 정형 데이터를 비정형 데이터로 변환

- 정형 데이터
  - 행과 열로 구성된 표와 같이 미리 정해 놓은 형식과 구조에 따라 저장되도록 구성된 데이터를 의미
  - 대표적인 정형 데이터는 관계형 데이터베이스의 테이블과 같이 고정된 컬럼에 저장되는 데이터를 예로 들 수 있음

정형 데이터와 비정형 데이터

아이디	이름	성별	연령	혈액형	1차	2차	3차	4차	5차
P330531	이겨레	남	26	A	13.25	13.11	13.25	13.33	13.58
P340037	조약돌	여	25	B	15.89	15.76	15.97	16.08	16.33
P194563	강산애	남	27	A	12.84	12.66	12.18	12.09	12.03
P503546	원미연	여	48	O	17.98	18.05	18.76	18.98	19.04
P330543	오대양	남	31	AB	15.23	15.47	15.69	15.82	15.88
P341257	송가인	여	45	O	18.98	18.75	18.67	18.59	18.03
P472358	성공찬	여	53	B	19.27	18.35	17.89	16.64	16.07
P185823	황산성	남	52	B	16.99	16.74	16.69	16.46	16.23
P232305	신영웅	남	19	AB	13.47	13.33	13.27	13.15	13.08
P489602	최고봉	남	64	A	20.23	21.08	21.98	22.03	23.57

그림 1-5 엑셀에서 생성한 바이오 정형 데이터

정형 데이터와 비정형 데이터

- 비정형 데이터
  - 정의된 구조가 없이 생성된 데이터를 의미하며 동영상 파일, 오디오 파일, 사진, 보고서, 메일 본문 등의 데이터가 비정형 데이터에 속함
  - 비정형 데이터를 생성할 때 텍스트 형태의 데이터는 전처리를 위해 자연어 처리 (NLP:Natural Language Processing) 기법을 주로 사용
  - 비정형 데이터는 주로 머신러닝을 위한 입력 데이터로 활용됨



그림 1-6 비정형 데이터인 텍스트에 대한 자연어 처리 과정

비즈니스 인텔리전스

- 비즈니스 인텔리전스(BI:Business Intelligence)
  - 기업에서 데이터를 수집하여 정리하고 분석된 결과를 활용하여 효율적인 의사결정을 하도록 수행하는 어플리케이션과 기술의 융합을 의미함
  - 의사결정 지원시스템, 조회 및 응답, 올랩(OLAP), 통계 분석, 예측 및 데이터 마이닝 등이 기본이 되며
  - 기업의 데이터베이스(DB)와 데이터 웨어하우스(DW), 기업 경쟁력을 강화시키는 역할을 하는 통합정보 시스템인 전사적 자원관리인 ERP 등과도 깊은 연관

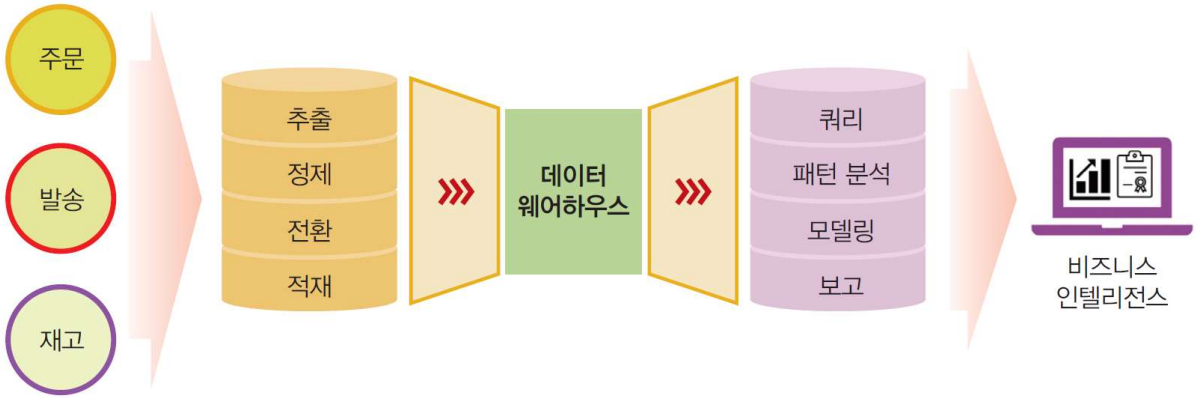


그림 1-7 비즈니스 인텔리전스 구성 요소

데이터 사이언티스트 등장 배경

- 데이터 사이언티스트(Data Scientist)
  - 많은 데이터 중에서 가치있는 데이터를 추출해내는 데이터 과학자를 의미하며
  - 누적된 많은 데이터를 분석하여 앞으로의 미래를 예측하고 모델링하며 이를 알고리즘 코드화를 수행하도록 지시하는 전문가



그림 1-8 데이터 사이언티스트의 등장 (출처 : 네이버)

데이터 사이언티스트 역량 개발

- 데이터 사이언티스트의 역량 개발
  - 데이터 사이언티스트는 데이터를 주도하여 의사를 결정하기 때문에 순수한 직관보다는 데이터 분석에 기반해 의사를 결정하는 행위가 무엇보다 중요하게 요구되고 있으며
  - 데이터가 특정 분야에서만 활용되는 시대는 이미 역사 속으로 사라지고 전반적인 산업 분야와 모든 사람에게 필요한 영역

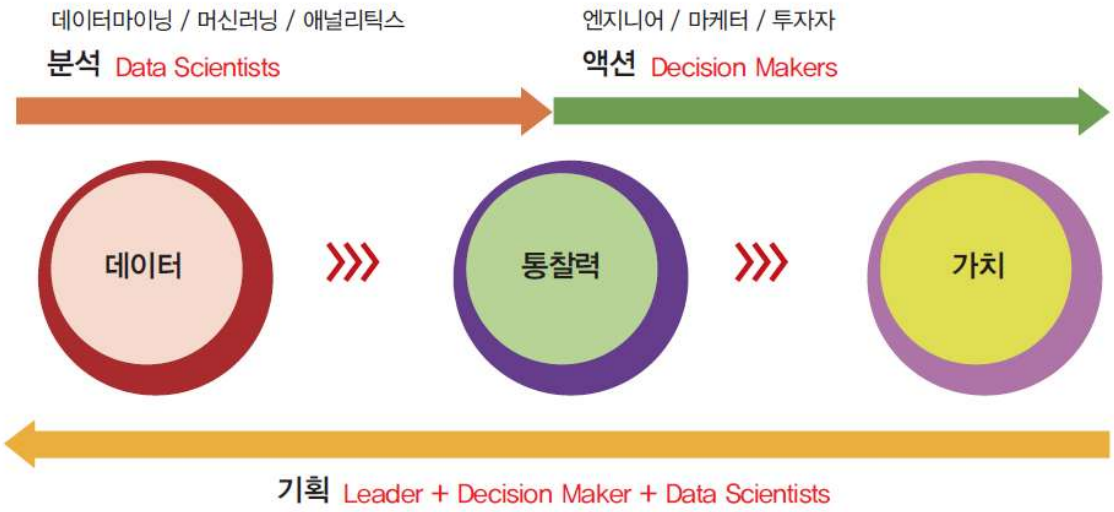


그림 1-9 데이터 사이언티스트의 역량 개발

데이터 사이언티스트 역량 개발

- 데이터 사이언티스트가 되기 위해 갖추어야 할 기본 역량에 대한 자가진단 테스트 과정 수행 필요

표 1-1 데이터 사이언티스트의 기본 역량 자가진단 테스트

질문 요지	예	아니오
1. 문제를 분석하고 정의할 수 있는가?	□	□
2. 문제 해결 절차를 수행할 수 있는가?	□	□
3. 데이터의 가치를 판단할 수 있는가?	□	□
4. 많은 데이터 속에서 패턴을 분석할 수 있는가?	□	□
5. 분석된 결과로 모델링을 구현할 수 있는가?	□	□
6. 알고리즘을 설계하고 코드화를 명령할 수 있는가?	□	□
7. 분석된 결과를 시각화할 수 있는가?	□	□
8. 미래를 예측할 수 있는 결과물을 제시할 수 있는가?	□	□

데이터 사이언티스트 마인드 세팅

- 데이터 사이언티스트의 마인트 세팅
  - 데이터 사이언티스트가 되기 위해서는 우선 사람들이 원하는 요구사항을 파악하는 것은 무엇보다 중요
  - 그러기 위해서는 주위에서 일어나는 여러 가지 현상들에 대한 깊은 통찰력과 데이터 가치에 대한 주인의식 고취가 필요함

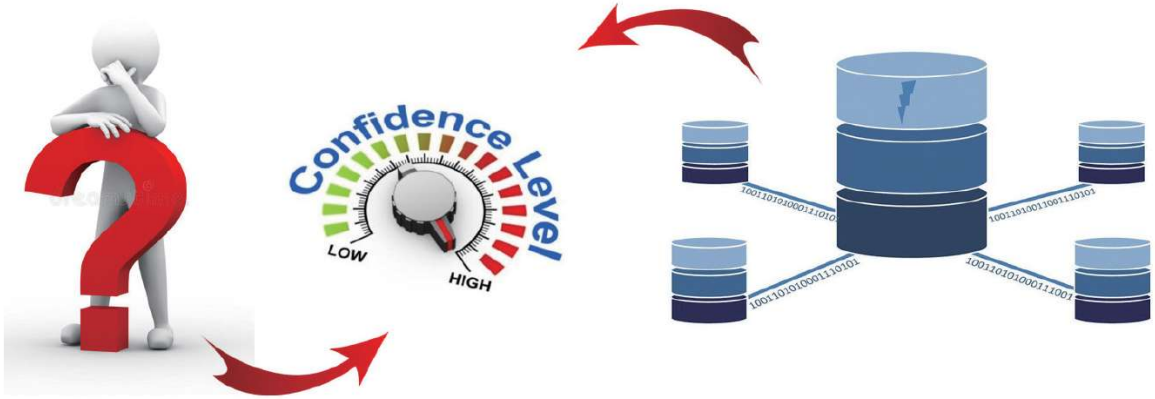


그림 1-10 데이터 사이언티스트의 마인드 세팅

사물인터넷

- 사물인터넷이란
  - 세상에 존재하는 유형과 무형의 디바이스(객체)들이 다양한 방식으로 연결되어 새로운 서비스를 제공하는 것을 의미
  - 사물인터넷의 표면적인 정의는 사물, 사람, 장소, 프로세스 등 유형과 무형의 사물들이 연결된 것을 의미하지만
  - 내면적으로 살펴보면 2개 이상의 사물들이 서로 연결됨으로써 개별적인 사물들이 하지 못했던 새로운 기능들을 제공할 수 있게 됨

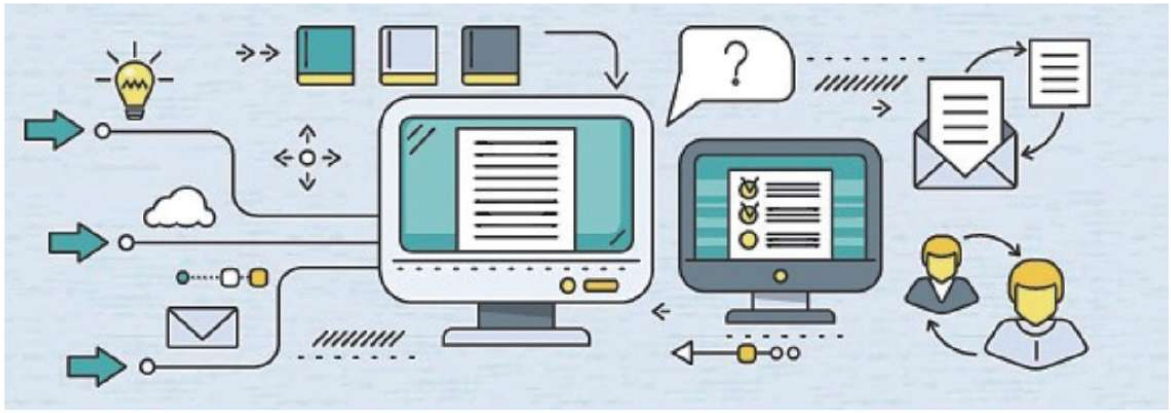


그림 1-11 사물인터넷 인프라 (출처 : 네이버)

빅데이터와 인공지능

- 빅데이터
  - 기존의 데이터베이스로는 수집, 저장, 분석 등을 정상적으로 수행하기 어려울 만큼 방대한 양의 데이터를 의미
  - 빅데이터는 디지털 환경에서 생성되는 데이터로 그 규모가 방대하고 생성 주기도 짧음
  - 형태 또한 수치 데이터에 정형 데이터 뿐만 아니라 문자와 영상 데이터 등의 비정형 데이터를 모두 포함하는 대규모 데이터를 다루는 영역



그림 1-12 빅데이터에 의한 산업의 지각변동 (출처 : 삼성경제연구소)

빅데이터와 인공지능

- 인공지능
  - 인간의 학습능력과 추론능력, 지각능력, 자연언어의 이해능력 등을 컴퓨터 프로그램으로 실현한 기술을 의미
  - 인공지능은 인간의 지능으로 할 수 있는 사고, 학습, 자기 계발 등을 컴퓨터가 스스로 수행할 수 있도록 방법을 연구하는 컴퓨터 공학 및 정보기술의 한 전문지식 분야임



그림 1-13 인공지능 적용 분야 (출처 : 네이버)

머신러닝과 딥러닝

- 인공지능 기술 분야
  - 인공지능은 머신러닝과 딥러닝으로 구성

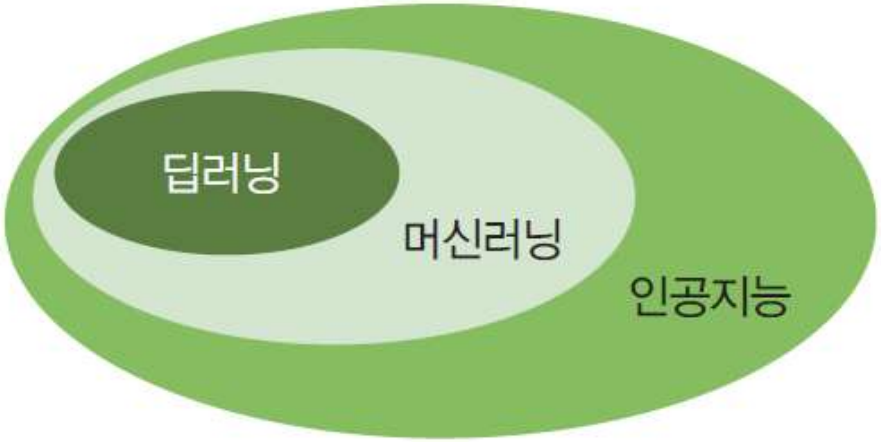


그림 1-14 인공지능 기술 영역

머신러닝과 딥러닝

- 머신러닝
  - 인공지능의 연구 분야 중 하나로 인간의 학습 능력과 같은 기능을 컴퓨터에서 실현하고자 하는 기술과 기법을 의미(기계학습)
  - 머신러닝은 패턴인식과 컴퓨터 학습 이론의 연구로부터 진화된 전문 분야임



그림 1-15 머신 러닝의 활용 목적

머신러닝과 딥러닝

- 딥러닝
  - 인공 신경망을 잇는 기계 학습법으로 사물이나 데이터를 군집화하거나 분류하는데 사용하는 기술
  - 구글은 음성인식과 번역을 비롯해 로봇의 인공지능 시스템 개발에도 딥러닝 기술을 도입

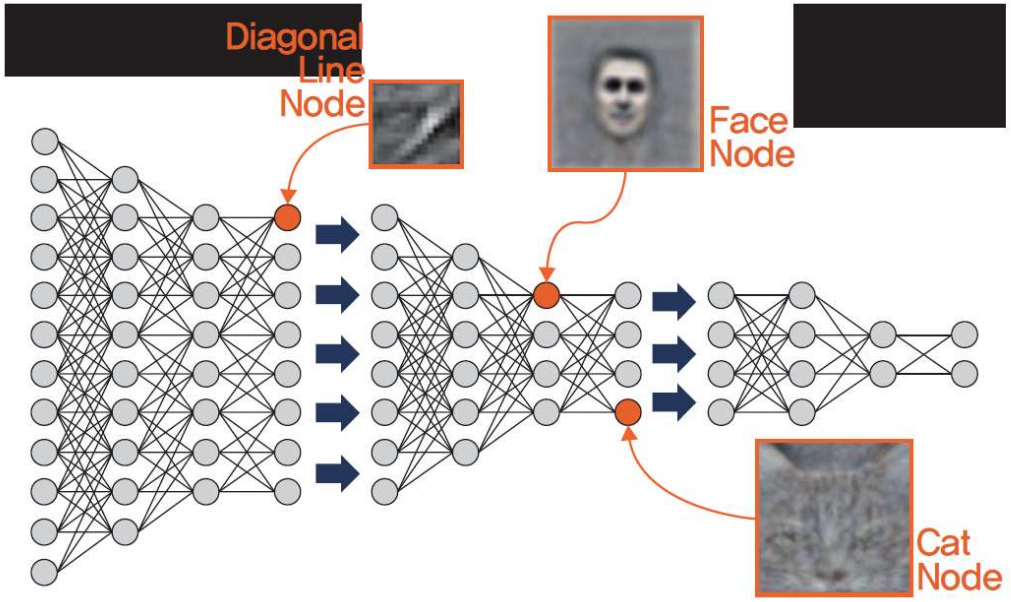


그림 1-16 유튜브 영상에서 고양이를 찾아내는 구글의 딥러닝 기술 (출처 : 네이버)

머신러닝과 딥러닝

- 인공 신경망의 DNA를 계승 받아 인공 신경망의 한계를 극복하기 위해 제안된 기계 학습이며 스스로 학습할 수 있다는 점이 머신 러닝과 가장 커다란 차별성임
- 인공지능 알고리즘을 오픈 소스로 제공하는 딥러닝으로는 '텐서플로'와 '파이토치'가 있음

여기서 잠깐! 텐서플로와 파이토치의 비교

텐서플로는 구글에서 개발하고 관리하는 딥러닝 기술로 이용자가 많기 때문에 딥러닝을 개발하는 과정에서 발생할 수 있는 여러 가지 이슈 사항들에 대한 정보 공유가 쉽다는 장점을 가지고 있으며, 파이토치는 파이썬 프로그램을 다루는 프로그래머들이 딥러닝을 개발하는데 매우 최적화된 프레임워크를 제공해 줍니다. 파이토치를 사용하는 프로그래머들은 텐서플로를 사용하는 프로그래머들보다 빈도는 크지 않지만 점점 증가하는 추세에 접어들었습니다. 파이토치는 페이스북을 개발하고 관리하는 파이토치의 전신인 토치를 기반으로 하고 있습니다. 둘 중 어느 것을 선택해서 사용할 것인가에 대한 결정은 각각의 장단점을 비교하여 본인에게 적합한 딥러닝을 선택하는 것이 가장 현명한 결정일 것입니다.

머신러닝과 딥러닝

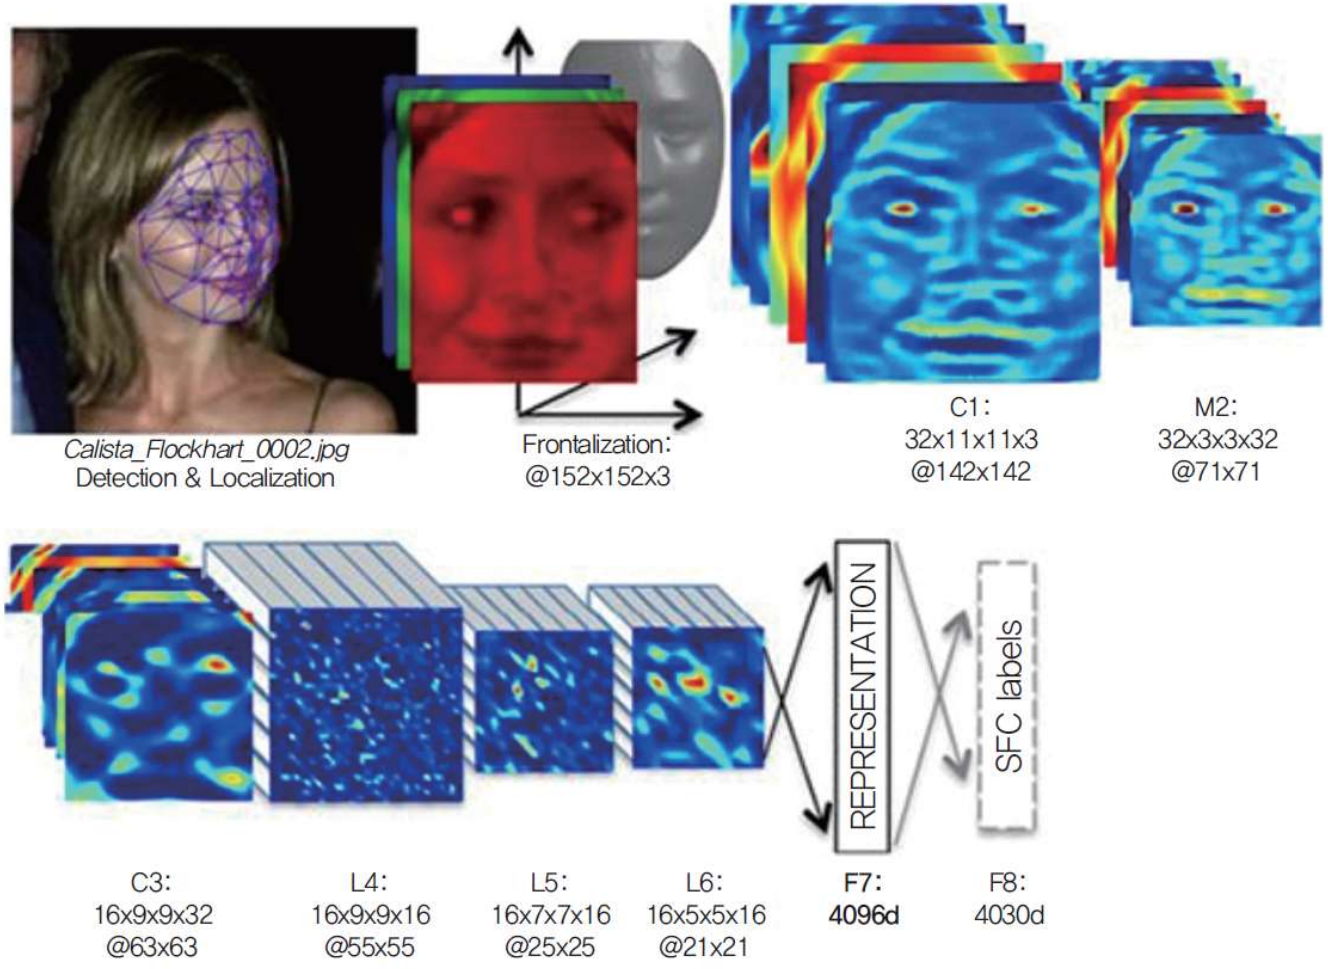


그림 1-17 페이스북의 딥페이스 동작 원리 (출처 : 네이버)

미래를 내다볼 수 있는 데이터 과학

- 데이터를 활용한 의사 결정과 미래 예측
  - 데이터 분석적 사고방식을 통한 의사결정으로 실패 확률을 줄이고 좀 더 명확한 미래를 예측

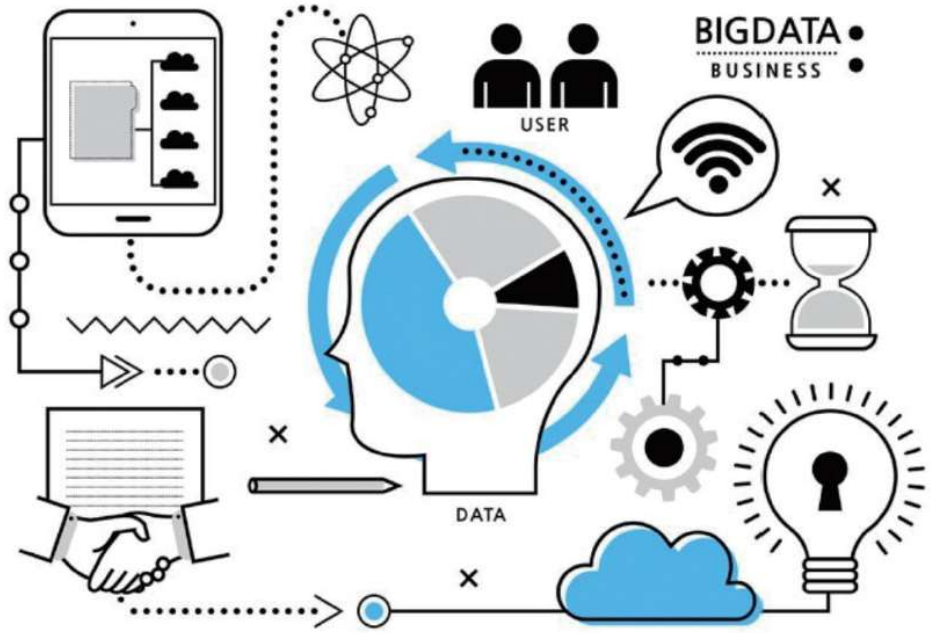


그림 1-18 데이터를 활용한 의사 결정과 미래 예측

3주차 과제 #1

E-class에 있는 3주차 과제 #1를 푸세요.

데이터 모델링이란?

- 주어진 문제를 해결하기 위해 복잡한 현실 세계에 존재하는 데이터를 단순화시켜 컴퓨터와 충분한 의사소통을 거쳐 데이터베이스로 옮기는 변환 과정을 의미
- 데이터 모델링을 수행하기 위해서는 복잡한 문제를 단순하게 분해하고 이를 논리적, 효율적으로 해결하기 위한 절차를 수행해야 함
- 데이터 모델링을 디자인하기 위해서는 요구사항 분석에 따른 창의력과 문제 분석 및 정의에 따른 문제 해결능력과 최선의 결정 검토



그림 3-1 데이터 모델링의 활용 절차

의사소통의 이해

- 인간관계에서 가지고 있는 생각이나 뜻이 서로 통한다는 것을 의미하며
- 의사소통은 구어나 문어를 통한 언어적 요소는 물론 제스처나 자세, 얼굴 표정, 눈맞춤, 목소리, 억양 등과 같은 비언어적 요소를 통해서도 이루어짐
- 개발자는 프로그래밍 언어를 통해 컴퓨터와 의사를 소통함



그림 3-2 개발자와 컴퓨터의 의사소통

의사소통의 이해

◦ 데이터 입력 : input( ) 함수

- 컴퓨터와 의사를 소통하려면 컴퓨터가 묻고 사용자가 답하는 프로그램을 수행해야 하며
- 파이썬 프로그램에서 키보드로 입력한 값을 처리할 때는 input( ) 함수를 사용함

```
변수명 = input("출력할 문자열 : ")
print(변수명) 또는 print("문자열", 변수명)
```

◦ input( ) 함수를 활용하여 성별에 대한 설문을 하는 의사소통 프로그램을 만들어보자.

```
01  print("■ 의사소통 프로그램 ")                    # 프로그램의 의미를 알리는 문자열 출력
02  gender = input("질문>> 당신의 성별은 : ")       # 키보드로 입력한 문자열을 변수에 대입
03  print("답변>> ", gender)                         # 변수에 대입한 문자열을 화면에 출력
```

의사소통의 이해

- 이번에는 답변에 "모름"이라고 입력해보자.

```
의사소통 프로그램
질문>> 당신의 성별은 : 모름
답변>>  모름
```

- 성별은 '남성'과 '여성'이라는 2개의 성별 중 하나를 선택해야 하지만 성별이 아닌 문자열을 입력하였음에도 불구하고 성별에 대한 결과는 그대로 출력되었음

- 어떻게 수정하면 좋을까?
  - 사용자가 입력한 값이 '남성' 또는 '여성'인지 확인하는 과정 필요
  - 만약 다른 문자열이 입력되면 다시 입력하도록 하거나 안내 메시지를 출력하도록 수정할 수 있음
  - 입력값을 검사하는 조건문을 추가하여 올바른 값만 처리하도록 개선

의사소통의 이해 - 전달 오류

- 의사소통이 실패하여 전달 오류가 발생하는 상황의 대표적인 예는 상대방의 표현을 제대로 듣지 않아 잘못 해석하는 경우가 대부분임
- 예를 들어 '스포츠카 ' 를 주문하였는데 해석 오류가 발생하여 의도하지 않은 '유람선 ' 을 납품 받았다고 가정한다면 심각한 오류 발생



그림 3-14 의사소통 오류 발생

의사소통의 이해 - 전달 오류

- 숫자와 문자열 판별 오류
  - 의사소통 오류는 컴퓨터와의 의사 전달 과정에서도 발생할 수 있으며 예를 들어 숫자 연산에 대한 결괏값을 기대하였으나
  - 프로그래밍 소스 코드를 잘못 작성하여 숫자가 문자열로 취급될 경우 프로그래머의 의도와 전혀 다른 엉뚱한 결과를 초래할 수 있음

- 논리 오류 발생
  - 논리 오류란 프로그램 문법구조에 위배되지는 않지만 프로그래머가 의도한대로 결과가 나타나지 않는 에러를 의미
  - print( ) 함수를 사용하여 10+20의 덧셈 연산 결과를 출력하는 과정에서 전달 오류로 인해 논리 오류가 발생하게 되는 경우를 살펴보기 위해 다음 예제를 수행

의사소통의 이해 - 전달 오류

- 논리 오류 발생 결과 확인하기
- 아래와 같이 덧셈 연산하는 프로그램을 만들어보자.

```
01  print("■ 전달 오류 프로그램 ")                  # 프로그램의 의미를 알리는 문자열 출력
02  result = print("덧셈 연산 : 10 + 20 ")         # print( ) 함수 안에 덧셈 연산식 입력
03  print("결괏값 : ", result)                      # 변수의 값을 화면에 출력
```

- 무엇이 문제인가?

의사소통의 이해 - 전달 오류

- 문법 오류 발생
  - 문법 오류는 파이썬 프로그램을 작성할 때 지켜야 할 문법 규칙을 위배하여 소스 코드를 작성할 경우 발생
  - print( ) 함수를 사용하여 10+20의 덧셈 연산 결과를 출력하는 과정에서 전달 오류로 인해
  - 문법 오류가 발생하게 되는 경우를 살펴보기 위해 다음 예제를 수행

- 아래와 같이 덧셈 연산하는 프로그램을 만들어보자.

```
01  print("■ 전달 오류 프로그램 ")                  # 프로그램의 의미를 알리는 문자열 출력
02  result = print("덧셈 연산 : " 10 + 20)         # 문자열과 연산식 사이에 콤마 누락
03  print("결괏값 : ", result)                      # 변수의 값을 화면에 출력
```

- 무엇이 문제인가?

명확한 의사 전달

- 의사 소통 성공
  - 자신의 의사를 상대방에게 제대로 전달하지 못하거나 분노를 조절하지 못하고 감정에 치우치게 되면 의사소통은 실패하게 됨
  - 명확한 의사를 전달하기 위해서 무엇보다 중요한 것은 바로 요구사항 분석을 정확하게 수행하는 것임



그림 3-15 명확한 의사 전달

명확한 의사 전달

◦ 문자열을 숫자로 변환 : eval( ) 함수

- eval( ) 함수는 문자열 형태의 값을 숫자 값으로 평가하고 변경하기 위해 사용하는 함수이며
- 앞에서 살펴본 input( ) 함수는 키보드로 입력한 값을 모두 문자열로 처리하므로 숫자도 문자열로 수행하지만
- eval( ) 함수는 문자열을 숫자로 변환하여 처리

```
변수명 = eval("10 + 20")
print(변수명) 또는 print("문자열", 변수명)
```

◦ **실습) 앞의 덧셈 연산하는 프로그램을 수행하면서 전달 오류로 인해 발생하는 논리 오류 또는 문법 오류를 eval() 함수를 사용하여 해결해보자.**

명확한 의사 전달 - 실습

도전 03 – 01 다음 지시사항을 수행하여 파이썬 소스 코드를 작성하시오.

1. print("10.5 + 23.8")과 같이 주어진 문자열을 숫자로 변환하기
2. result 변수에 문자열이 변환된 덧셈 연산식 대입하기
3. 소스 코드는 CP03-01.jpynb 파일명으로 저장하기
4. 기타 사항은 출력 예시를 참조하여 작성하기

■ 문자열을 숫자로 처리하는 프로그램

문제>> 10.5 + 23.8의 덧셈 연산

결과>> 34.3

3주차 과제 #2

E-class에 있는 3주차 과제 #2를 푸세요.