데이터사이언스

Lecture 12 데이터 정규화 및 회귀분석

정규화(Normalization)란?

데이터를 정규분포에 가깝게 변환하는 작업

왜 정규성이 중요한가?

- 많은 통계 검정(t-test, ANOVA, 회귀)이 정규성 가정을 전제한다.
- 정규분포에서 평균은 중심을 잘 대표하고 신뢰구간 계산도 정확하다.
- ML 모델 중 거리·확률 기반 알고리즘(SVM, 로지스틱회귀)의 안정성↑
- 왜도가 크면 평균이 이상치에 끌려가 분석 결과가 왜곡된다.

정규화 ≠ 스케일링

두 용어는 자주 혼용되지만 목적이 다르다.

구분	스케일링	정규화 (오늘)
목적	범위 통일	분포 모양 변경
대표 기법	MinMax, Z-score	로그, Box-Cox
결과 분포	원본과 같은 모양	정규분포에 가까움
관심사	단위·크기	왜도·첨도

정규성 진단 -시각적 방법

먼저 눈으로 분포를 확인하는 것이 가장 빠르고 직관적이다.

① 히스토그램 (Histogram)

분포의 전반적인 모양을 한눈에 파악.
좌우 대칭 종 모양이면 정규분포 후보.

```
import seaborn as sns
sns.histplot(df['연소득'], kde=True, bins=30)
# kde=True → 커널밀도추정 곡선
# 종 모양 vs 치우친 분포 확인
```

② QQ-plot (Quantile-Quantile)

실제 분위수 vs 정규분포 분위수를 점으로 비교.
점들이 직선에 가까우면 정규분포에 가깝다.

```
from scipy import stats
import matplotlib.pyplot as plt
stats.probplot(df['연소득'], dist='norm', plot=plt)
plt.show()  # 직선에서 벗어날수록 비정규
```

③ 박스플롯 (Boxplot) — 보조 지표

박스플롯은 정규성 자체를 직접 보여주진 않지만, 좌우 대칭성과 이상치를 동시에 확인할 수 있어 유용하다.

- 중앙선이 박스 가운데 → 좌우 대칭 (정규성 가능)
- 중앙선이 한쪽에 치우침 → 왜도 존재 → 변환 필요 신호
- 수염(whisker) 길이가 비슷 → 양쪽 꼬리 균형

matplotlib 기초 — figure와 subplot

예제 코드에 자주 등장하는 matplotlib의 화면 분할 문법을 정리한다.

핵심 개념 두 가지

figure (그림 전체) = 도화지 한 장
axes (서브플롯) = 도화지 위의 각 그래프 영역

figsize=(가로, 세로) — 인치 단위 크기

용도	코드
단일 그래프	`plt.figure(figsize=(8, 5))`
좌우 1×2 분할	`fig, axes = plt.subplots(1, 2, figsize=(12, 4))`
상하 2×1 분할	`fig, axes = plt.subplots(2, 1, figsize=(8, 8))`
2×2 격자	`fig, axes = plt.subplots(2, 2, figsize=(10, 8))`

axes 배열 접근법

```
# 1차원 (1×N 또는 N×1)
axes[0]    # 첫 번째 그래프
axes[1]    # 두 번째 그래프

# 2차원 (2×2 격자)
axes[0, 0] # 좌상  /  axes[0, 1] # 우상
axes[1, 0] # 좌하  /  axes[1, 1] # 우하
```

실전 예시 — 1×2 분할

```
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
axes[0].hist(df['콜레스테롤'])     # 좌: 히스토그램
axes[1].boxplot(df['콜레스테롤'])  # 우: 박스플롯
plt.tight_layout()  # 그래프 간격 자동 조정
plt.show()
```

기본 matplotlib은 한글을 □□□로 표시한다.

```
!pip install koreanize-matplotlib
import koreanize_matplotlib   # 이 한 줄로 한글 폰트 + 음수 부호까지 자동 설정
```

week12_data.csv 변수 설명

이 데이터는 환자 200명의 건강검진 데이터입니다.

변수명	타입	설명	범위/값
환자ID	문자열	고유 식별자	P001 ~ P200
나이	정수	환자 나이 (세)	30 ~ 70
성별	범주	남 / 여	남 55% · 여 45%
흡연	범주	흡연 여부	Y / N (남자 35%, 여자 10% 흡연)
BMI	실수	체질량지수 (kg/m²)	17.0 ~ 32.2
혈압	정수	수축기 혈압 (mmHg)	90 ~ 156
혈당	정수	공복 혈당 (mg/dL)	70 ~ 163
콜레스테롤	정수	총 콜레스테롤 (mg/dL)	130 ~ 229
운동시간	실수	주간 운동 시간	0 ~ 12, 결측 6개
진단	범주	종합 진단 등급	건강 124 · 주의 60 · 위험 16
약물복용	범주	약물 복용 여부	Y / N
체중_전	실수	측정 1차 체중 (kg)	46.3 ~ 96.4
체중_후	실수	측정 2차 체중 (kg)	45.7 ~ 92.8

예제 ① 히스토그램 · QQ-plot 그리기

문제

week12_data.csv의 '콜레스테롤' 열에 대해 히스토그램과 QQ-plot을 동시에 그리세요.
1×2 subplot으로 좌측에 히스토그램(KDE 곡선 포함), 우측에 QQ-plot을 배치합니다.

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

df = pd.read_csv('week12_data.csv', encoding='cp949')

fig, axes = plt.subplots(1, 2, figsize=(12, 4))

# 좌측: 히스토그램 + KDE
sns.histplot(df['콜레스테롤'], kde=True, bins=25, ax=axes[0], color='steelblue')
axes[0].set_title('Histogram of 콜레스테롤')

# 우측: QQ-plot
stats.probplot(df['콜레스테롤'], dist='norm', plot=axes[1])
axes[1].set_title('Q-Q Plot')

plt.tight_layout()
plt.show()
```

정규성의 통계적 의미

정규분포 (Normal Distribution)

평균 μ를 중심으로 좌우 대칭이며,
표준편차 σ에 따라 퍼짐이 결정되는 종 모양 분포.

$$f(x) = (1 / \sqrt{(2\pi\sigma^2)}) \cdot \exp(-(x-\mu)^2 / 2\sigma^2)$$

$$X \sim N(\mu, \sigma^2)$$

68 - 95 - 99.7 규칙

정규분포에서는 평균으로부터 ±1σ 안에 약 68%, ±2σ 안에 95%, ±3σ 안에 99.7%의 데이터가 포함된다.

이 규칙이 성립한다면 평균과 표준편차만으로 데이터의 99.7%를 설명할 수 있다는 뜻이다.

신뢰구간 계산, 이상치 탐지(±3σ 기준)의 근거가 바로 이 규칙이다.

정규성에서 벗어나는 두 축

왜도 (Skewness) — 좌우 비대칭

skew ≈ 0 → 대칭 (정규)
skew > 0 → 오른쪽 꼬리 (양의 왜도)
skew < 0 → 왼쪽 꼬리 (음의 왜도)

|skew| > 1 → 변환 강력 권장

첨도 (Kurtosis) — 뾰족함

kurt ≈ 0 → 정규분포 (excess kurtosis)
kurt > 0 → 뾰족하고 꼬리 두꺼움
kurt < 0 → 납작하고 꼬리 얇음

pandas.kurt()는 excess kurtosis 반환

정규성 검정 — 통계적 방법

시각적 진단 이후에는 통계 검정으로 정량적 판단을 한다.

정규성 검정의 공통 가설

H_0 (귀무가설): 데이터가 정규분포를 따른다. vs H_1 (대립가설): 데이터가 정규분포를 따르지 않는다.
→ p-value > 0.05 : H_0 채택 (정규성 만족) p-value ≤ 0.05 : H_0 기각 (정규성 위배)

① Shapiro-Wilk Test

- 표본 수 ≤ 5000일 때 가장 강력한 검정
- 소규모 표본(n < 50)에서도 우수한 성능
- scipy.stats.shapiro() 사용

② Kolmogorov-Smirnov Test

- 표본 수가 매우 클 때 사용
- 누적분포함수(CDF) 차이를 측정
- 분포의 위치·척도를 알아야 정확

```
from scipy import stats
stat, p = stats.shapiro(df['연소득'])
print(f'Shapiro-Wilk: stat={stat:.4f}, p={p:.4f}')
if p > 0.05: print('정규성 만족')
else: print('정규성 위배 → 변환 필요')
```

예제 ② Shapiro-Wilk 정규성 검정

문제

콜레스테롤·혈당·BMI·운동시간 4개 변수에 대해 Shapiro-Wilk 검정을 수행하고,
정규성 만족 여부(p > 0.05)와 함께 결과를 표 형태로 출력하세요.

```
cols = ['콜레스테롤', '혈당', 'BMI', '운동시간']
results = []
for col in cols:
    data = df[col].dropna()
    stat, p = stats.shapiro(data)
    verdict = '정규성 만족' if p > 0.05 else '정규성 위배'
    results.append({'변수': col, '통계량': round(stat, 4),
                    'p-value': round(p, 4), '판정': verdict})

print(pd.DataFrame(results))
```

변환 기법 ① 로그 변환 (Log Transformation)

가장 자주 쓰이는 변환

오른쪽 꼬리가 긴(양의 왜도) 데이터를 정규분포에 가깝게 만든다

y = log(x)　　또는　　y = log(1 + x)

언제 사용?

- 소득, 매출, 가격 등 양의 값이며 분포가 오른쪽으로 치우친 경우
- 값의 범위가 매우 넓을 때 (수십 ~ 수억)
- 곱셈적 관계를 덧셈적 관계로 바꾸고 싶을 때
- 의학·생물학에서 농도, 효소 활성 등에 자주 사용

주의: 0과 음수는 불가

log(0) = −∞ 이므로 0을 포함한 데이터는 log1p(x) = log(1+x)를 사용한다.
음수가 있다면 로그 변환 자체가 불가능 → Yeo-Johnson 권장.

실전 코드

```
import numpy as np

# 0 없는 데이터
df['소득_log'] = np.log(df['소득'])

# 0 포함 가능한 데이터
df['소득_log'] = np.log1p(df['소득'])
# log1p(x) = log(1+x)
```

```
# 변환 효과 검증
before = df['소득'].skew()
after  = df['소득_log'].skew()
print(f'변환 전 왜도: {before:.2f}')
print(f'변환 후 왜도: {after:.2f}')
# 1.0 이상 → 0.5 이하면 성공
```

예제 ③ 로그 변환 전후 비교

문제

왜도가 가장 큰 '운동시간' 열에 log1p 변환을 적용하고,
변환 전후 왜도와 Shapiro-Wilk p-value를 비교하여 효과를 확인하세요.

```
import numpy as np

x = df['운동시간'].dropna()

# 변환 전
print(f'[변환 전]  왜도 = {x.skew():.3f}, '
      f'Shapiro p = {stats.shapiro(x)[1]:.4f}')

# log1p = log(1 + x) — 0 입력에 안전
x_log = np.log1p(x)

print(f'[로그 변환] 왜도 = {x_log.skew():.3f}, '
      f'Shapiro p = {stats.shapiro(x_log)[1]:.4f}')
```

변환 기법 ② 제곱근 · 역수 변환

제곱근 변환 (Square Root)

$$y = \sqrt{x}$$

특징

- 로그보다 약한 변환 효과
- 양의 왜도가 약~중간 수준일 때 적합
- 카운트 데이터(0 포함 가능)에 자주 사용
- 푸아송분포 → 정규분포 변환에 효과적

```
df['cnt_sqrt'] = np.sqrt(df['리뷰수'])

# 효과 비교
print(df['리뷰수'].skew())
print(df['cnt_sqrt'].skew())
```

역수 변환 (Reciprocal)

$$y = 1 / x$$

특징

- 변환 강도가 매우 강함
- 극단적인 양의 왜도에 효과적
- 값의 순서가 역전됨에 유의
- 0은 불가, 음수면 부호 확인 필요

```
df['x_inv'] = 1 / df['반응시간']

# 0 방지
df['x_inv'] = 1 / (df['x'] + 1e-6)
```

변환 기법 ③ Box-Cox 변환

최적의 변환 강도(λ)를 자동으로 찾아주는 통합 변환

Box-Cox 변환식

```
y(λ) = (x^λ - 1) / λ,     λ ≠ 0
y(λ) = log(x),     λ = 0
```

λ는 데이터로부터 최우추정으로 자동 산출
λ=1: 변환 없음 λ=0.5: 제곱근 λ=0: 로그 λ=−1: 역수

Box-Cox의 강점과 제약

✓ 여러 변환을 한 함수로 통합 (로그·제곱근·역수 포함)
✓ 데이터에 가장 적합한 λ를 자동 탐색
✓ 최우추정(MLE)으로 통계적 근거 명확

⚠ 양수만 가능 — 0 또는 음수가 있으면 사용 불가
⚠ 변환된 값은 원본 단위가 아님 → 해석 시 역변환 필요
⚠ 음수 포함 데이터는 Yeo-Johnson 사용

```python
from scipy import stats

# Box-Cox 변환 + 최적 λ
transformed, lam = stats.boxcox(df['소득'])
df['소득_bc'] = transformed
print(f'최적 λ = {lam:.3f}')

# sklearn으로도 가능
from sklearn.preprocessing \
  import PowerTransformer
pt = PowerTransformer(method='box-cox')
df['소득_bc'] = pt.fit_transform(df[['소득']])
```

예제 ④ Box-Cox 최적 λ 탐색

문제

혈당 열에 Box-Cox 변환을 적용하여 최적 λ를 찾고,
λ값이 어떤 변환에 가까운지 해석하세요. (λ≈0: 로그, λ≈0.5: 제곱근, λ≈1: 변환 없음)

```
x = df['혈당'].dropna()

# Box-Cox 변환 + 최적 λ 산출
transformed, lam = stats.boxcox(x)

print(f'최적 λ = {lam:.3f}')
print(f'변환 전 왜도 = {x.skew():.3f}')
print(f'변환 후 왜도 = {pd.Series(transformed).skew():.3f}')

# 해석
if abs(lam) < 0.2:
    print('→ 로그 변환에 가까움')
elif abs(lam - 0.5) < 0.15:
    print('→ 제곱근 변환에 가까움')
else:
    print(f'→ λ={lam:.2f} 의 거듭제곱 변환')
```

변환 기법 ④ Yeo-Johnson 변환

Box-Cox의 일반화 버전 — 음수도 처리 가능

구분	Box-Cox	Yeo-Johnson
입력값	양수만 가능 (x > 0)	음수·0·양수 모두 가능
변환식	단순 (단일 식)	x의 부호에 따라 다른 식 적용
최적 λ 탐색	MLE 기반 자동	MLE 기반 자동
주요 사용처	양의 데이터 (소득, 가격)	혼합 부호 (수익률, 변화량)
sklearn 메서드	PowerTransformer('box-cox')	PowerTransformer('yeo-johnson')

```
from sklearn.preprocessing import \
    PowerTransformer

pt = PowerTransformer(method='yeo-johnson')
df['x_yj'] = pt.fit_transform(df[['수익률']])
print(pt.lambdas_)  # 학습된 λ 확인
```

선택 가이드

✓ 양수만 있는 경우 → Box-Cox
✓ 음수 또는 0이 섞여 있다면 → Yeo-Johnson
✓ 해석이 중요 → 로그/제곱근 (수동)
✓ 모델 성능 우선 → Box-Cox / Yeo-Johnson

정규화 실전 — 통합 파이프라인

정규성 진단 → 변환 → 효과 검증의 3단계 워크플로우

```
import numpy as np, pandas as pd
from scipy import stats
from sklearn.preprocessing import PowerTransformer

# Step 1. 정규성 진단
def check_normality(x, name):
    skew_v = pd.Series(x).skew()
    stat, p = stats.shapiro(x)
    print(f'[{name}] 왜도={skew_v:.3f}, Shapiro p={p:.4f}')
    return p > 0.05

# Step 2. 변환 (양의 왜도 + 양수 데이터 가정)
x = df['연소득'].dropna()
check_normality(x, '원본')

x_log = np.log1p(x);     check_normality(x_log, '로그')
x_sqrt = np.sqrt(x);     check_normality(x_sqrt, '제곱근')
x_bc, lam = stats.boxcox(x)
check_normality(x_bc, f'Box-Cox(λ={lam:.2f})')

# Step 3. 가장 정규성에 가까운 변환 선택 → 컬럼 갱신
```

정규화 예제

week11_shop.csv를 사용하세요. (encoding='cp949')

Q1	연소득 열의 히스토그램과 QQ-plot을 그리고, 정규성 여부를 시각적으로 판단해보자.
Q2	Shapiro-Wilk 검정으로 연소득의 정규성을 통계적으로 검정하라. p-value는 얼마인가?
Q3	로그 변환 후 왜도가 얼마나 변했는가? 변환 전후 값을 비교하라.
Q4	Box-Cox 변환을 적용하고 최적 λ값을 찾아라. λ가 어떤 변환에 가까운지 해석하라.
Q5	변환 전과 변환 후의 Shapiro-Wilk p-value를 비교하여 어떤 변환이 가장 효과적이었는지 결론을 내려라.

추론통계 (Inferential Statistics) 도입

기술통계 (Descriptive)

우리가 가진 데이터를 요약·정리하는 것
→ 평균, 분산, 분포 모양

예: '우리 반 100명의 평균 키는 168cm이다.'

추론통계 (Inferential)

표본 데이터로 모집단의 특성을 추정·검증
→ 가설검정, 신뢰구간

예: '한국인 평균 키는 168 ± 2cm일 것이다.'

핵심 개념

모집단 (Population)

관심 있는 전체 대상
예: 모든 한국인

표본 (Sample)

모집단에서 추출한 일부
예: 설문 응답자 1000명

통계량 (Statistic)

표본에서 계산한 값
예: 표본 평균

가설검정의 5단계 (Hypothesis Testing)

어떤 가설검정이든 이 5단계는 동일하다.

1 가설 설정

H_0: 차이 없음
H_1: 차이 있음

2 유의수준 결정

보통 $\alpha = 0.05$
엄격 시 $\alpha = 0.01$

3 검정통계량 계산

t, F, χ^2 등
데이터로부터 계산

4 p-value 산출

통계량의 극단성
확률

5 결론

$p < \alpha$: H_0 기각
$p \geq \alpha$: H_0 채택

두 가지 오류를 기억하라

1종 오류 (Type I): H_0가 참인데 기각 — '실제로는 차이 없는데 있다고 잘못 결론' → 확률 = α (유의수준)
2종 오류 (Type II): H_0가 거짓인데 채택 — '실제로는 차이 있는데 없다고 잘못 결론' → 확률 = β, 검정력 = $1-\beta$

유의수준(α)과 p-value

p-value의 정확한 정의

"귀무가설이 참이라고 가정했을 때, 현재 관찰된 결과(또는 더 극단적인 결과)가 나올 확률"
p-value가 작을수록 → 귀무가설 하에서 보기 드문 사건 → 귀무가설이 틀렸을 가능성이 높다고 판단

유의수준 α의 선택

α	신뢰수준	사용 상황
0.10	90%	탐색적 분석
0.05	**95%**	**일반적 기준 (기본값)**
0.01	99%	엄격한 의사결정 (의학)
0.001	99.9%	매우 엄격 (안전 분야)

의사결정 흐름

p-value < α

귀무가설 H_0 기각 → 통계적으로 유의미
→ 효과/차이가 존재한다고 결론

p-value ≥ α

귀무가설 H_0 채택 → 통계적으로 유의미하지 않음
(반드시 'H_0가 참'은 아님 — 증거 부족)

t-검정 ① 단일표본 t-test (One-sample)

한 집단의 평균이 특정 값과 다른지 검정한다.

사용 상황

한 집단의 평균이 알려진 값(기준값)과 다른지 확인할 때.

예시:
- 신약 복용 환자 30명의 평균 혈압이 정상 기준(120)과 다른가?
- 우리 학생들의 평균 점수가 전국 평균(75점)과 다른가?
- 우리 회사 상품의 평균 무게가 표시 무게(500g)와 다른가?

가설 설정

H_0: $\mu = \mu_0$ (집단 평균이 기준값과 같다)
H_1: $\mu \neq \mu_0$ (양측검정) 또는 $\mu > \mu_0$ / $\mu < \mu_0$ (단측검정)

전제 조건: 표본이 정규분포에 가까움 (n ≥ 30이면 중심극한정리로 완화)

Python 코드

```
from scipy import stats

# 환자 30명의 혈압이 120과 다른가?
bp = df['혈압']

t_stat, p = stats.ttest_1samp(
    bp, popmean=120)

print(f't = {t_stat:.3f}')
print(f'p-value = {p:.4f}')

if p < 0.05:
    print('기준값과 유의한 차이 있음')
else:
    print('차이가 유의미하지 않음')
```

예제 ⑤ 단일표본 t-test

문제

환자들의 평균 혈압이 정상 기준(120 mmHg)과 다른지 검정하세요.

H_0: $\mu = 120$, H_1: $\mu \neq 120$, 유의수준 $\alpha = 0.05$

```
bp = df['혈압']
t_stat, p = stats.ttest_1samp(bp, popmean=120)

print(f'표본 평균 = {bp.mean():.2f} mmHg')
print(f't 통계량 = {t_stat:.3f}')
print(f'p-value  = {p:.4f}')

if p < 0.05:
    print('→ 정상 기준 120과 통계적으로 유의한 차이가 있다.')
else:
    print('→ 정상 기준 120과 유의한 차이가 없다.')
```

t-검정 ② 독립표본 t-test (Two-sample)

두 독립된 집단의 평균이 다른지 검정한다.

전제 조건 — 등분산 가정에 따라 함수가 달라진다

1) 정규성: 각 집단이 정규분포에 가까움 (n ≥ 30이면 완화)
2) 독립성: 두 집단이 서로 영향을 주지 않음
3) 등분산성: Levene 검정으로 확인 (p > 0.05면 등분산 가정)

```
# 1단계. 등분산 검정
from scipy import stats

male = df[df['성별']=='남']['구매금액']
female = df[df['성별']=='여']['구매금액']

lev_stat, lev_p = stats.levene(
    male, female)
print(f'Levene p = {lev_p:.4f}')
# p > 0.05 → 등분산 가정 가능
```

```
# 2단계. t-test 수행
if lev_p > 0.05:
    # 등분산 가정
    t, p = stats.ttest_ind(
        male, female, equal_var=True)
else:
    # 이분산 → Welch's t-test
    t, p = stats.ttest_ind(
        male, female, equal_var=False)

print(f't={t:.3f}, p={p:.4f}')
```

예제 ⑥ 독립표본 t-test — 흡연 vs 비흡연

문제
흡연자와 비흡연자의 평균 혈압이 다른지 검정하세요.
Levene 등분산 검정 후, 결과에 따라 적절한 t-test를 선택합니다.

```
yes = df[df['흡연']=='Y']['혈압']
no  = df[df['흡연']=='N']['혈압']

# 1단계: 등분산 검정
_, lev_p = stats.levene(yes, no)
print(f'Levene p = {lev_p:.4f}')

# 2단계: 등분산 결과에 따라 t-test
equal_var = lev_p > 0.05
t, p = stats.ttest_ind(yes, no, equal_var=equal_var)

print(f'흡연자 평균   = {yes.mean():.2f}')
print(f'비흡연자 평균 = {no.mean():.2f}')
print(f't = {t:.3f}, p = {p:.4f}')
```

t-검정 ③ 대응표본 t-test (Paired)

같은 대상의 사전/사후를 비교할 때 사용한다.

왜 독립표본 t-test와 다른가?

독립표본 검정은 '집단 A vs 집단 B'를 비교한다. 두 집단의 개체는 서로 다른 사람들이다.
대응표본 검정은 '같은 사람의 전 vs 후'를 비교한다. 사람마다의 기본 차이를 제거하므로 검정력이 더 높다.
→ 핵심 통계량은 각 사람의 차이(d = 후 − 전)의 평균이 0과 다른지 검정한다.

예시 상황

- 다이어트 프로그램 전후 체중 비교
- 약물 투여 전후의 환자 혈압 변화
- 수업 전후 학생들의 평가 점수 변화
- 쇼핑몰 개편 전후 같은 고객의 구매액

```
from scipy import stats

# 다이어트 전후 체중
before = df['체중_전']
after  = df['체중_후']

t, p = stats.ttest_rel(before, after)
print(f't = {t:.3f}, p = {p:.4f}')
```

예제 ⑦ 대응표본 t-test — 체중 변화

문제

같은 환자의 체중_전과 체중_후를 비교하여 유의미한 변화가 있는지 검정하세요.
H_0: 평균 차이 = 0, H_1: 평균 차이 ≠ 0

```
before = df['체중_전']
after  = df['체중_후']

t, p = stats.ttest_rel(before, after)

print(f'평균 차이 (전-후) = {(before - after).mean():.2f} kg')
print(f't = {t:.3f}, p = {p:.4f}')

if p < 0.05:
    print('→ 체중 변화가 통계적으로 유의하다.')
else:
    print('→ 체중 변화가 유의하지 않다.')
```

분산분석 — ANOVA (Analysis of Variance)

3개 이상의 집단 평균을 동시에 비교한다.

왜 t-test를 여러 번 쓰면 안 되는가?

4개 집단을 t-test로 비교하려면 ${}_4C_2 = 6$번을 검정해야 한다. 각 검정마다 $\alpha=0.05$의 오류 가능성이 있으므로 전체 1종 오류 확률은 $1 - (0.95)^6 \approx 26\%$로 급증한다. → 한 번에 검정하는 ANOVA가 필요한 이유.

일원분산분석 (One-way ANOVA)

가설 설정

H_0: $\mu_1 = \mu_2 = \mu_3 = \ldots = \mu_k$
(모든 집단 평균이 같다)

H_1: 적어도 한 쌍은 다르다

F-통계량 = 집단 간 분산 / 집단 내 분산

F가 클수록 집단 간 차이가 두드러진다.

```
from scipy import stats

# 등급별 구매금액 평균 비교
bronze = df[df['등급']=='BRONZE']['구매금액']
silver = df[df['등급']=='SILVER']['구매금액']
gold   = df[df['등급']=='GOLD']['구매금액']
vip    = df[df['등급']=='VIP']['구매금액']

f, p = stats.f_oneway(
    bronze, silver, gold, vip)
print(f'F={f:.3f}, p={p:.4f}')
```

사후검정 (Post-hoc Test) — Tukey HSD

ANOVA 다음에 반드시 따라오는 분석

ANOVA는 "어떤 차이가 있다"는 사실만 알려준다. 어느 집단끼리 다른지는 알려주지 않는다.
→ 사후검정으로 구체적인 쌍별 비교를 수행한다. 가장 널리 쓰이는 방법이 Tukey HSD.

주요 사후검정 방법

방법	특징
Tukey HSD	가장 일반적, 표본 크기 동일할 때 강력
Bonferroni	보수적, 다중비교에 안전
Scheffé	표본 크기 다를 때 적합
Dunnett	대조군과 각 처리군 비교

```
import statsmodels.api as sm
from statsmodels.stats.multicomp \
    import pairwise_tukeyhsd

result = pairwise_tukeyhsd(
    endog=df['구매금액'],
    groups=df['등급'],
    alpha=0.05)

print(result)
# reject=True인 쌍이 통계적으로 유의
```

예제 ⑧ 일원분산분석 (ANOVA) + Tukey HSD

문제

진단 3그룹(건강·주의·위험)의 BMI 평균에 차이가 있는지 ANOVA로 검정한 뒤,
사후검정(Tukey HSD)으로 어느 쌍에서 차이가 나는지 밝히세요.

```
from statsmodels.stats.multicomp import pairwise_tukeyhsd

# 1단계: ANOVA
groups = [df[df['진단']==g]['BMI'] for g in ['건강', '주의', '위험']]
f_stat, p = stats.f_oneway(*groups)
print(f'F = {f_stat:.3f}, p = {p:.4f}')

# 2단계: Tukey HSD 사후검정
result = pairwise_tukeyhsd(endog=df['BMI'],
                           groups=df['진단'], alpha=0.05)
print(result)
```

카이제곱 검정 (Chi-square Test)

범주형 변수 간 독립성·동질성을 검정한다.

① 독립성 검정 (Test of Independence)

두 범주형 변수가 서로 독립인가?

예: '성별과 등급은 독립적인가?'
'학력과 정당 선호는 연관이 있는가?'
→ pd.crosstab으로 교차표 생성 후 검정

② 적합도 검정 (Goodness of Fit)

관측 빈도가 기대 분포와 일치하는가?

예: '주사위가 공정한가?' (모두 1/6 기대)
'A:B:C 상품 판매가 1:1:1인가?'
→ 관측 vs 기대 빈도 비교

```
import pandas as pd
from scipy.stats import chi2_contingency

# 독립성 검정: 성별 × 등급
ct = pd.crosstab(df['성별'], df['등급'])
chi2, p, dof, expected = chi2_contingency(ct)
print(f'χ²={chi2:.3f}, p={p:.4f}, 자유도={dof}')
# p < 0.05 → 두 변수는 독립이 아님 (관련 있음)
```

검정 선택 가이드 (Decision Tree)

상황에 맞는 통계 검정을 한눈에 선택할 수 있도록 정리한다.

데이터 유형	비교 대상	검정 방법	Python 함수
수치형 (정규)	1집단 vs 기준값	단일표본 t-test	`stats.ttest_1samp`
수치형 (정규)	독립된 2집단	독립표본 t-test	`stats.ttest_ind`
수치형 (정규)	같은 대상 전/후	대응표본 t-test	`stats.ttest_rel`
수치형 (정규)	3집단 이상	일원분산분석 (ANOVA)	`stats.f_oneway`
수치형 (비정규)	2집단	Mann-Whitney U	`stats.mannwhitneyu`
수치형 (비정규)	3집단 이상	Kruskal-Wallis	`stats.kruskal`
범주형 × 범주형	독립성/연관성	카이제곱 검정	`stats.chi2_contingency`
수치형 × 수치형	선형 관계	Pearson 상관	`stats.pearsonr`

정규성이 위배되면 모수 검정 대신 비모수 검정(non-parametric test) 사용 — Mann-Whitney U, Kruskal-Wallis 등

회귀분석 (Regression Analysis) 도입

변수 간 관계를 수식으로 표현하여 예측에 활용한다.

01
관계 파악

변수 X가 Y에 어떤 영향을 미치는가?
방향과 크기를 정량화한다.

02
예측

X 값이 주어졌을 때
Y 값을 추정한다.

03
통제 변수 효과

다른 변수를 통제한 상태에서
특정 변수의 순효과를 본다.

Y 변수 형태에 따른 회귀 종류

Y 변수 형태	회귀 종류	예시
연속형 (수치)	선형회귀 (Linear)	키 → 몸무게, 광고비 → 매출
이진형 (0/1)	로지스틱 회귀 (Logistic)	흡연 → 폐암 발병 여부
다중 클래스	다항 로지스틱 회귀	고객 → 상품군 분류
카운트	포아송 회귀	지역 → 사고 발생 횟수

단순선형회귀 (Simple Linear Regression)

모집단 모형: $Y = \beta_0 + \beta_1 X + \varepsilon$ **추정 회귀식:** $\hat{Y} = \hat{\beta_0} + \hat{\beta_1} X$

회귀계수의 의미

- β_0 (절편): X=0일 때의 Y 값
- β_1 (기울기): X가 1 증가할 때 Y의 평균 변화량
- ε (오차항): $\varepsilon \sim N(0, \sigma^2)$ 가정
- 잔차 $e_i = y_i - \hat{y}_i$: 실제값과 예측값의 차이

최소제곱법 (Ordinary Least Squares, OLS)

잔차제곱합(SSE)을 최소화하는 $\hat{\beta}_0, \hat{\beta}_1$을 찾는 방법

$$\min \sum (y_i - \hat{\beta_0} - \hat{\beta_1} x_i)^2$$

→ 잔차가 가장 작은 직선이 최적 회귀선

OLS 추정량 (닫힌 해)

$$\hat{\beta_1} = \Sigma(x_i - \bar{x})(y_i - \bar{y}) \,/\, \Sigma(x_i - \bar{x})^2$$

$$\hat{\beta_0} = \bar{y} - \hat{\beta_1} \cdot \bar{x}$$

```
import statsmodels.formula.api as smf

model = smf.ols(
    '매출 ~ 광고비', data=df).fit()

print(model.summary())
```

예제 ⑨ 단순선형회귀 — 나이 → 콜레스테롤

문제
나이를 독립변수로 콜레스테롤을 예측하는 단순선형회귀를 적합하고,
회귀식, R^2, p-value를 출력한 뒤 산점도에 회귀선을 그려보세요.

```
import statsmodels.formula.api as smf

# 회귀 적합
model = smf.ols('콜레스테롤 ~ 나이', data=df).fit()
print(model.summary())

# 시각화
plt.figure(figsize=(8, 5))
plt.scatter(df['나이'], df['콜레스테롤'], alpha=0.5, color='steelblue')
plt.plot(df['나이'], model.fittedvalues, color='red', lw=2)
plt.xlabel('나이'); plt.ylabel('콜레스테롤')
plt.title(f'R² = {model.rsquared:.3f}')
plt.show()
```

회귀분석 도구 선택 — sklearn vs statsmodels

같은 회귀분석이라도 목적에 따라 사용하는 라이브러리가 다르다.

	sklearn	statsmodels
주 목적	예측 (Prediction)	추론·해석 (Inference)
출력 정보	계수, 절편, R^2 (간결)	계수, t-value, p-value, 신뢰구간, F-검정 등 (풍부)
ANOVA 테이블	직접 제공 X	anova_lm() 함수로 즉시 출력
summary() 메서드	없음	있음 (모든 통계량 한 번에)
함수 호출 방식	`LinearRegression().fit(X,y)`	`smf.ols('y~x', data=df).fit()`
추천 상황	ML 파이프라인, 교차검증, 예측 중심	통계적 해석, 보고서, 논문, 가설검정

오늘은 statsmodels로 진행한다

회귀계수의 유의성 검정, ANOVA 테이블, R^2 등 통계적 해석에 집중하기 때문이다.

statsmodels summary() — 한 줄씩 읽기

model.summary() 출력의 각 항목을 정확하게 해석할 수 있어야 한다.

model.summary() 예시 출력

```
                OLS Regression Results
==========================================
Dep. Variable:         매출      R-squared:     0.842
Model:                 OLS       Adj. R-squared: 0.838
No. Observations:      100       F-statistic:    258.6
Df Residuals:           98       Prob(F-stat):  1.2e-38
==========================================
             coef    std err      t    P>|t|
------------------------------------------
Intercept   45.21     3.812    11.86   0.000
광고비       1.503    0.094    16.02   0.000
==========================================
```

핵심 항목 해석

R-squared
모델이 설명하는 분산 비율 (0~1, 클수록 좋음)

Adj. R-squared
변수 개수 보정한 R^2 (다중회귀에서 비교)

F-statistic / Prob(F)
회귀 전체가 유의한가? p<0.05면 유의

coef
추정된 회귀계수 ($\hat{\beta}$)

std err
계수의 표준오차 — 추정 정밀도

t / P>|t|
각 계수가 0과 다른가? p<0.05면 유의

분산 분해 — SST = SSR + SSE

관측값의 총 변동을 모델이 설명하는 부분과 설명하지 못하는 부분으로 분해한다.

$$SST = SSR + SSE$$

SST

Total Sum of Squares

$$\Sigma (y_i - \bar{y})^2$$

전체 변동
(평균 대비 관측값의 흩어짐)

SSR

Regression Sum of Squares

$$\Sigma (\hat{y}_i - \bar{y})^2$$

회귀로 설명되는 변동
(예측값이 평균에서 떨어진 정도)

SSE

Error Sum of Squares

$$\Sigma (y_i - \hat{y}_i)^2$$

회귀로 설명되지 못하는 변동
(잔차 = 실제 − 예측)

회귀 ANOVA 테이블

요인	제곱합	자유도	평균제곱	F
회귀	SSR	k	MSR = SSR/k	**MSR / MSE**
잔차	SSE	n−k−1	MSE = SSE/(n−k−1)	
전체	SST	n−1		

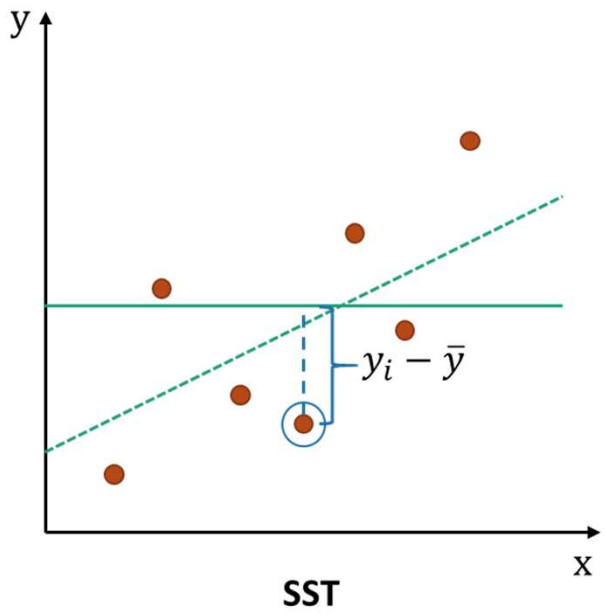
결정계수 R^2 (Coefficient of Determination)

$$R^2 = SSR / SST = 1 - SSE / SST$$

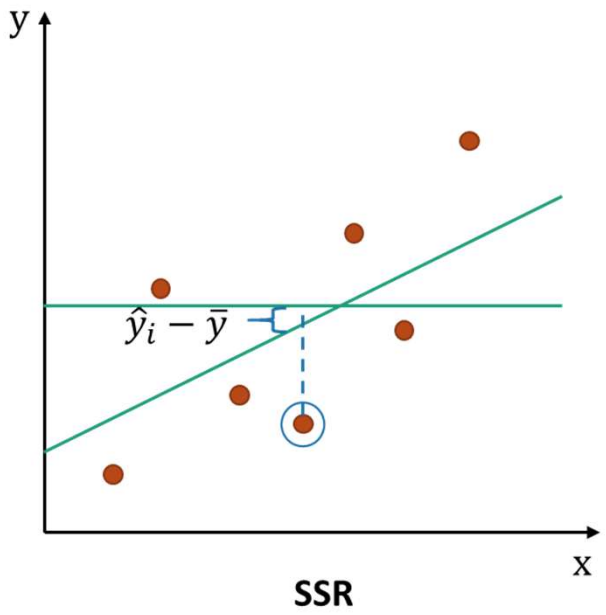
$0 \le R^2 \le 1$ 1에 가까울수록 설명력↑
R^2=0.21 → 모델이 Y 분산의 21%를 설명

회귀모형의 유의성

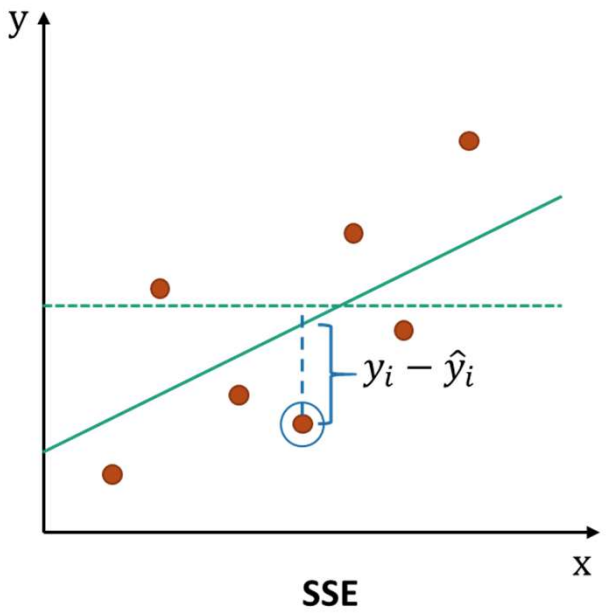
- $SST = SSR + SSE$
- SST(Total sum of squares): 전체제곱합 $\sum_{i=1}^{n}(y_i - \bar{y})^2$
- SSR(Regression sum of squares): 회귀제곱합 $\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2$
- SSE(Error sum of squares): 오차제곱합 $\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$



SST



SSR



SSE

다중선형회귀 (Multiple Linear Regression)

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_k X_k + \varepsilon$$

주요 평가 지표

지표	의미
R^2	모델이 설명하는 분산의 비율 (0~1)
adj R^2	변수 개수를 보정한 R^2
RMSE	예측 오차의 표준편차 (단위 동일)
p-value	각 계수의 통계적 유의성
VIF	다중공선성 진단 (>10 위험)

```python
import statsmodels.formula.api as smf
import statsmodels.api as sm

# 공식 표기로 직관적
model = smf.ols(
    '매출 ~ 광고비 + 직원수 + 지점수',
    data=df).fit()

# 회귀 요약
print(model.summary())

# ANOVA 테이블
print(sm.stats.anova_lm(model))
```

예제 ⑩ 다중선형회귀 + ANOVA 테이블

문제
나이·BMI·혈압을 독립변수로 콜레스테롤을 예측하는 다중회귀를 적합하고,
summary와 ANOVA 테이블을 출력한 뒤 각 변수의 유의성을 해석하세요.

```
import statsmodels.api as sm

# 다중회귀 적합
model = smf.ols(
    '콜레스테롤 ~ 나이 + BMI + 혈압', data=df).fit()

# 회귀 요약 (계수·p-value·R²)
print(model.summary())

# ANOVA 테이블 (각 변수의 SS, F, p)
print(sm.stats.anova_lm(model, typ=2))
```

회귀 진단 (Regression Diagnostics)

회귀모델이 신뢰할 만한지 4가지 가정을 점검해야 한다.

① 선형성

X와 Y가 선형 관계인가?
→ 잔차 vs 적합값 산점도 (패턴 없어야)

② 정규성

잔차가 정규분포를 따르는가?
→ 잔차의 QQ-plot, Shapiro-Wilk

③ 독립성

잔차들이 서로 독립인가?
→ Durbin-Watson (1.5~2.5 정상)

④ 등분산성

잔차의 분산이 일정한가?
→ Breusch-Pagan 검정

12주차 과제

week12_health.csv 데이터를 이용하여 e-Class 과제를 푸세요. (encoding='cp949')

변수	설명
환자ID	고유 번호
나이	환자 나이 (세)
BMI	체질량지수 (kg/m²)
혈압	수축기 혈압 (mmHg)
콜레스테롤	총 콜레스테롤 (mg/dL)
성별 / 흡연 / 운동	남/여, Y/N, Y/N
진단	건강 / 주의 / 위험 (3 클래스)
당뇨여부	0 / 1 (이진)